language model = cara yang assign probabilitas kepada sequence of words

word embeeding = efek samping dari language model karena kita encode ke suatu baris

(Distributed Word Representations) Word Embeddings

Alfan F. Wicaksono
Information Retrieval Lab.
Faculty of Computer Science
Universitas Indonesia

How to more robustly match a user's intent?

Query: "**motel** di depok"

Sistem diharapkan tidak hanya mengembalikan dokumen tentang "**motel** di depok"; tetapi juga "**hotel** di depok", "**penginapan** di depok", dsb.

Expansion Using Query Logs

Context-Free Query Expansion

- Misal, dari analisis query logs didapatkan bahwa **“wet ground”** = **“wet earth”**.
- Oleh karena itu, jika kedepannya ada query term **“ground”**, perlu di-expand dengan term **“earth”**.

- Problem: **“ground coffee”** -> **“earth coffee”** ??

Thesaurus-based Approach

Contoh: Path-based similarity

Two terms are similar if they are near each other in the thesaurus hierarchy.

$$\text{simpath}(c_1,c_2) = \frac{1}{\text{pathlen}(c_1,c_2)}$$

$$\text{wordsim}(w_1,w_2) = \max_{c_1 \in \text{senses}(w_1), c_2 \in \text{senses}(w_2)} \text{sim}(c_1,c_2)$$

simpath(*nickel,coin*) = 1/2 = .5

simpath(*fund,budget*) = 1/2 = .5

simpath(*nickel,currency*) = 1/4 = .25

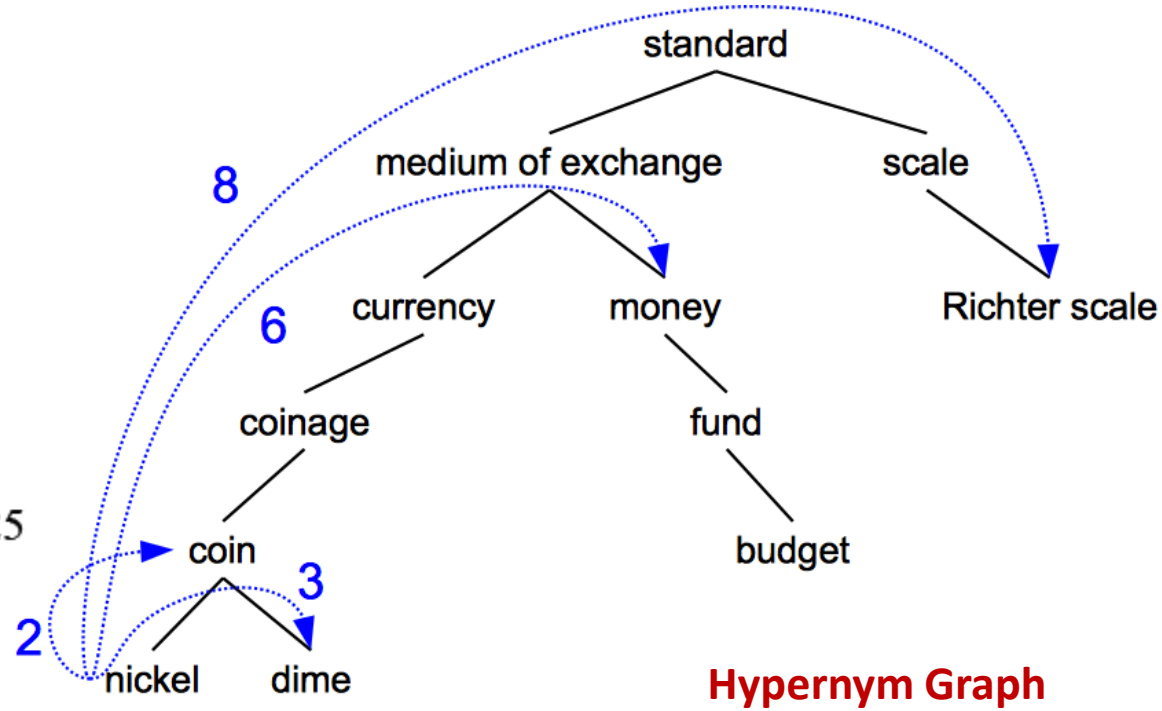

Hypernym Graph

Dan Jurafsky

Thesaurus-based Approach

Problems...

- We don’t have a thesaurus for every language

- For Indonesian, our WordNet is not complete
  - Many words are missing
  - Connections between senses are missing
  - …

Word -> Vector; Term Relations?

Pada konsep VSM standar, setiap term menjadi **basis/axis** di vector space.

Query: "hotel"

Document: "motel motel motel"

$$q = [0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, \dots, 0]$$

$$d = [0, 0, 3, 0, 0, 0, 0, 0, 0, 0, 0, \dots, 0]$$

$$sim(q, d) = q.d^T = 0$$

Orthogonal!

Word -> Vector; Term Relations?

Pada konsep VSM standar, setiap term menjadi **basis/axis** di vector space.

$$sim(q, d) = q.d^T$$

q = "hotel di depok"

$$[1, 0, 1, 1] \times \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} = 2.0$$

hotel motel di depok

Make Sense?

d = "motel di depok"

Orthogonal!

Word -> Vector; Term Relations?

Query Translation Model (Berger & Lafferty, 99)

Tambahkan **trainable parameter W** untuk menangkap **similarity** atau **translasi** antar kata.

	hotel	motel	di	depok
hotel	1.0	0.8	0.0	0.0
motel	0.8	1.0	0.0	0.0
di	0.0	0.0	1.0	0.0
depok	0.0	0.0	0.0	1.0

Word -> Vector; Term Relations?

Query Translation Model (Berger & Lafferty, 99)

Tambahkan parameter **W** untuk menangkap similarity antar kata.

$$sim(q, d) = q.W.d^T$$

q = "hotel di depok"

$$[1, 0, 1, 1] \times \begin{bmatrix} 1.0 & 0.8 & 0.0 & 0.0 \\ 0.8 & 1.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 1.0 \end{bmatrix} \times \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} = 2.8$$

hotel, motel, di, depok

Better!

d = "motel di depok"

Tetap saja isu Sparsity muncul. Ukuran W besar!

Distributional-based Approach

- Can we learn a **dense low-dimensional** representation of a word such that dot products $u.v^T$ express word similarity?

- Masih mungkin juga menyisipkan “translation” matrix antar vocab (misal, cross-language): $u.W.v^T$

Distributional-based Approach

- Based on the idea that contextual information alone constitutes a viable representation of linguistic items.
- As opposed to formal lingustics and the Chomsky tradition.

- Zellig Haris (1954): "...**if A and B have almost identical environments, we say that they are synonyms**..."

- J. R. Firth (1957): "**You shall know a word by the company it keeps**"

Distributional-based Approach

gogos

Ada yang tahu apa itu **gogos**?

Distributional-based A

Makan **gogos** dengan sambal sungguh nikmat.
Beras ketan diperlukan untuk membuat **gogos**.
Teman-teman menikmati **gogos** hangat di kantin.
Menikmati makanan **gogos**, lemper dari makasar.

- From context words humans can guess ***gogos*** means
  - A traditional food
- Intuition for algorithm:
  - **Two words are similar if they have similar word contexts**

Latent Semantic Analysis

Alin Revisited: Rank

Let C be an M × N matrix. The **rank** of a matrix is the number of **linearly independent rows** (or columns) in it; thus, **rank(C) ≤ min{M, N}**.

$$C = \begin{bmatrix} 2 & 4 & 8 \\ 1 & 2 & 4 \end{bmatrix}, \qquad rank(C) = 1$$

$$C = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \qquad rank(C) = 3$$

Alin Revisited: Rank

Let C be an M × N matrix. The **rank** of a matrix is the number of **linearly independent rows** (or columns) in it; thus, **rank(C) ≤ min{M, N}**.

Secara umum, ubah dahulu ke bentuk **Row-Echelon Form**; lalu hitung ada **berapa baris yang non-zero**.

$$C = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 1 & 4 \\ 3 & 0 & 5 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -2 \\ 0 & -6 & -4 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

$R_2 \rightarrow R_2 - 2R_1$
$R_3 \rightarrow R_3 - 3R_1$

$R_3 \rightarrow R_3 - 2R_2$

Rank(C) = 2

Alin Revisited: Eigenvector

For a square M × M matrix C and a non-zero vector **x**, the values of λ satisfying

$$Cx = \lambda x$$

are called the **eigenvalues** of C.

x disebut **eigenvetor**.

Banyaknya non-zero eigenvalues dari C adalah paling banyak Rank(C).

Contoh:

$$C = \begin{bmatrix} -6 & 3 \\ 4 & 5 \end{bmatrix}$$

$$x_1 = \begin{bmatrix} 1 \\ 4 \end{bmatrix} \quad \lambda_1 = 6$$

$$x_2 = \begin{bmatrix} -3 \\ 1 \end{bmatrix} \quad \lambda_2 = -7$$

Alin Revisited: Eigenvector

Singkat cerita, eigenvector tidak akan berubah arah ketika ditransformasi (hanya memanjang atau memendek).

“ditransformasi” = “dikali matriks”

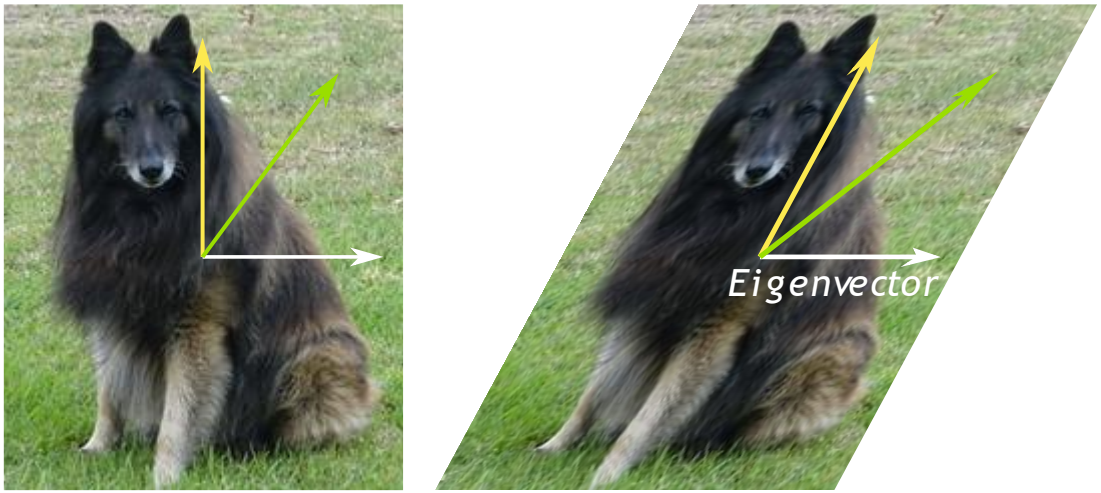

https://www.mathsisfun.com/algebra/eigenvalue.html

Alin Revisited: Eigenvector

Sekedar istilah …

Right-eigenvector of C $Cx = \lambda x$

$$C = \begin{bmatrix} -6 & 3 \\ 4 & 5 \end{bmatrix} \quad x = \begin{bmatrix} 1 \\ 4 \end{bmatrix} \quad \lambda = 6$$

Left-eigenvector of C $y^T C = \lambda y^T$

$$C = \begin{bmatrix} -6 & 3 \\ 4 & 5 \end{bmatrix} \quad y^T = [? \quad ?] \quad \lambda = ?$$

Latihan: cari sebuah left-eigenvector dari C!

Vector Space Model

Term-Document Matrix

Each cell is the count of word *t* in document *d* (bisa juga TF-IDF)

	D1	D2	D3	D4	D5
ekonomi	0	1	40	38	1
pusing	4	5	1	3	30
keuangan	1	2	30	25	2
sakit	4	6	0	4	25
inflasi	8	1	15	14	1

Vector of D2 = [1, 5, 2, 6, 1]

Vector Space Model

Term-Document Matrix

Each cell is the count of word *t* in document *d* (bisa juga TF-IDF)

	D1	D2	D3	D4	D5
ekonomi	0	1	40	38	1
pusing	4	5	1	3	30
keuangan	1	2	30	25	2
sakit	4	6	0	4	25
inflasi	8	1	15	14	1

Two documents are similar if they have similar vector!

D3 = [40, 1, 30, 0, 15]

D4 = [38, 3, 25, 4, 14]

Vector Space Model

Term-Document Matrix

Each cell is the count of word *t* in document *d* (bisa juga TF-IDF)

	D1	D2	D3	D4	D5
ekonomi	0	1	40	38	1
pusing	4	5	1	3	30
keuangan	1	2	30	25	2
sakit	4	6	0	4	25
inflasi	8	1	15	14	1

Vector of word "sakit" = [4, 6, 0, 4, 25]

Vector Space Model

Term-Document Matrix

Each cell is the count of word *t* in document *d* (bisa juga TF-IDF)

	D1	D2	D3	D4	D5
ekonomi	0	1	40	38	1
pusing	4	5	1	3	30
keuangan	1	2	30	25	2
sakit	4	6	0	4	25
inflasi	8	1	15	14	1

Two words are similar if they have similar vector!

pusing = [4, 5, 1, 3, 30]

sakit = [4, 6, 0, 4, 25]

Vector Space Model

Jika **C** adalah term-document matrix,

$C.C^T$ mengandung dot products (similarity) dari semua pasangan **term vectors**; dan

$C^T.C$ mengandung dot products (similarity) dari semua pasangan **document vectors**.

Dekomposisi Term-Document Matrix!

Misal, C adalah term-document matrix. C didekomposisi menjadi perkalian 3 matrix (**Singular Value Decomposition**).

$$C = U \times \Sigma \times V^T \qquad C \in R^{M \times N}$$

Cell selain titik = 0

Jika M > N

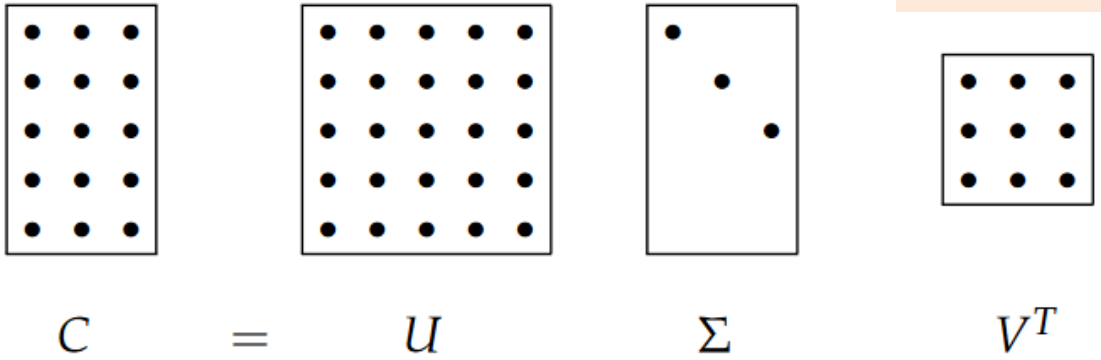

Jika M < N

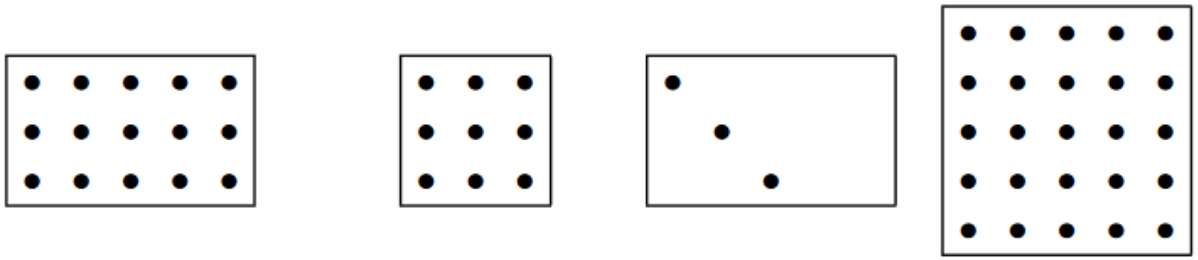

Cara menghitung U, ∑, dan V^T

Kolom-kolom pada U adalah orthogonal eigenvector dari $C.C^T$

Baris-baris pada V^T adalah orthogonal eigenvector dari $C^T.C$

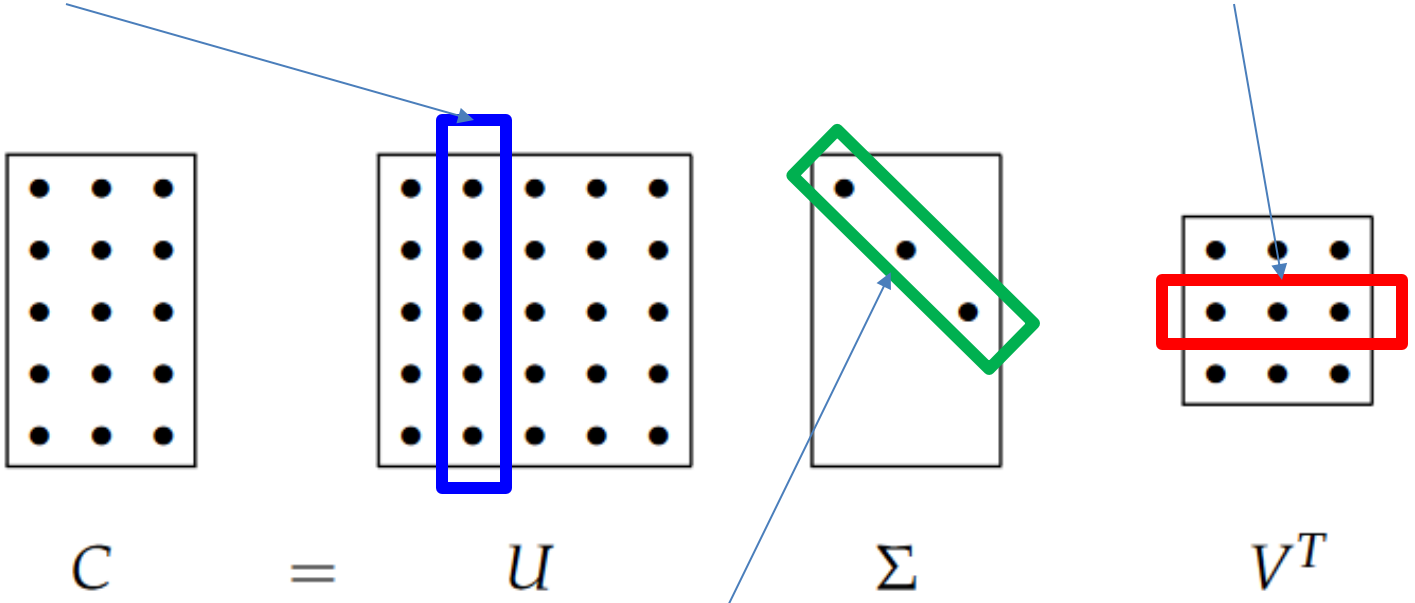

Singular Values (Akar kuadrat dari Eigenvalues) dari $C^T.C$ atau $C.\ C^T$ (sama saja).

Truncated SVD

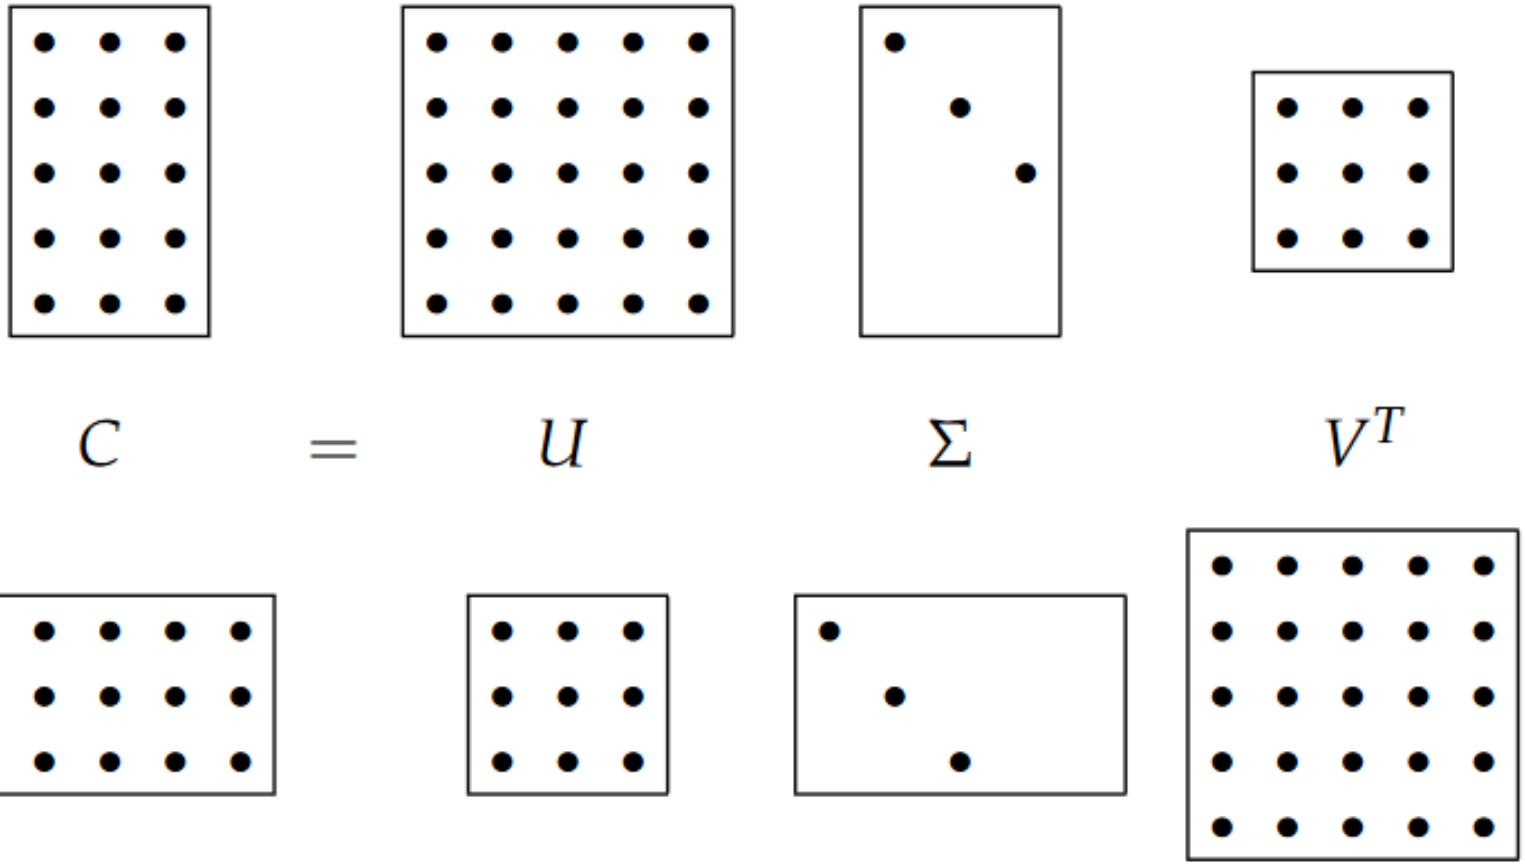

Truncated SVD

$$L = Rank(C)$$

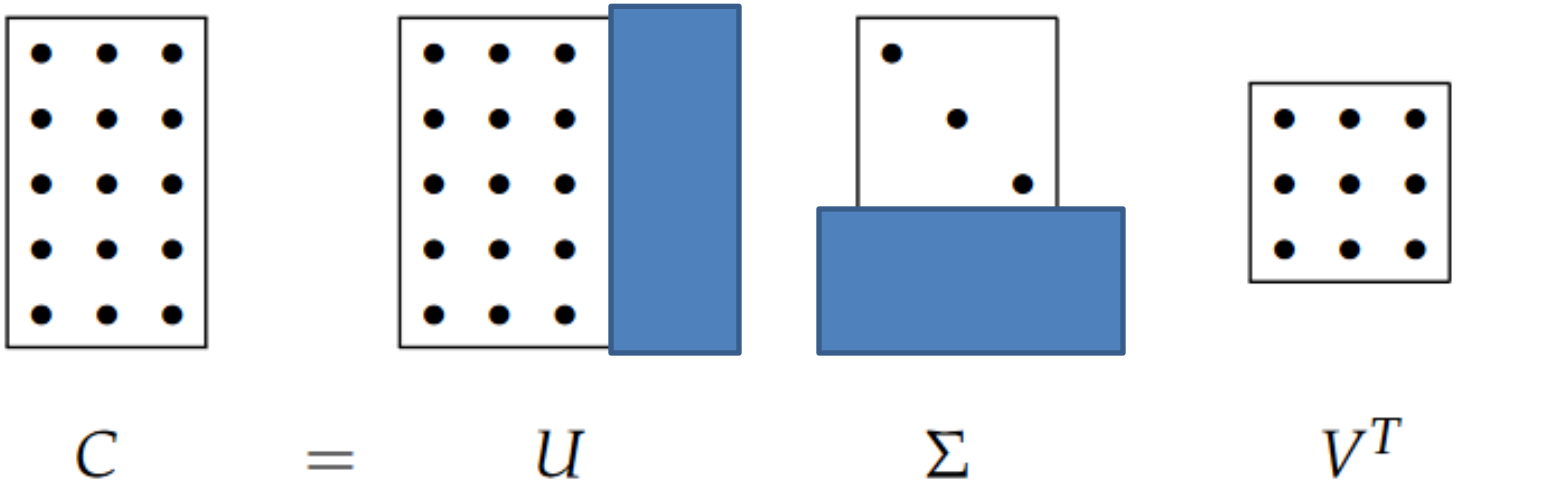

$C = U \Sigma V^T$

M x N = M x L · L x L · L x N

Interpretasi Truncated SVD

Misal, C adalah term-document matrix. C didekomposisi menjadi perkalian 3 matrix.

$$C = U \times \Sigma \times V^T$$

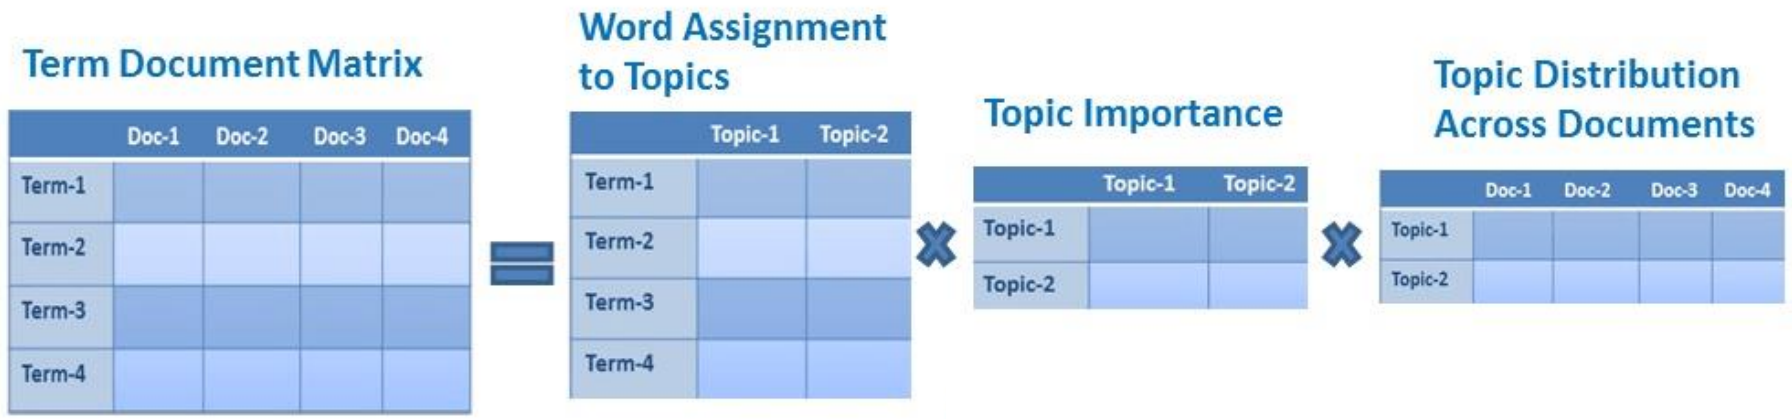

Gambar: https://www.datacamp.com/tutorial/discovering-hidden-topics-python

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

C

Σ

				truncated
18.93	0	0	0	0
0	14.49	0	0	0
0	0	2.60	0	0
0	0	0	0.86	0

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

V^T

← truncated

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

Beberapa fakta:

Kolom-kolom **U** saling **orthogonal** dan merupakan **basis baru** untuk **dokumen-dokumen (kolom pada C)** di ruang yang baru (hasil rotasi).

Σ

				truncated
18.93	0	0	0	0
0	14.49	0	0	0
0	0	2.60	0	0
0	0	0	0.86	0

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

L2-Norm = 1

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

V^T

truncated

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

Beberapa fakta:

Baris-baris $\mathbf{V^T}$ saling **orthogonal** dan merupakan **basis baru** untuk **term-term (baris pada C)** di ruang yang baru (hasil rotasi).

Σ

				truncated
18.93	0	0	0	0
0	14.49	0	0	0
0	0	2.60	0	0
0	0	0	0.86	0

U

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

V^T

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

L2-Norm = 1

truncated

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

Review Aljabar Linear

Dot product dapat digunakan untuk memproyeksikan sebuah vektor ke himpunan basis-basis yang **orthogonal** pada sebuah ruang vektor (untuk dapat koordinat).

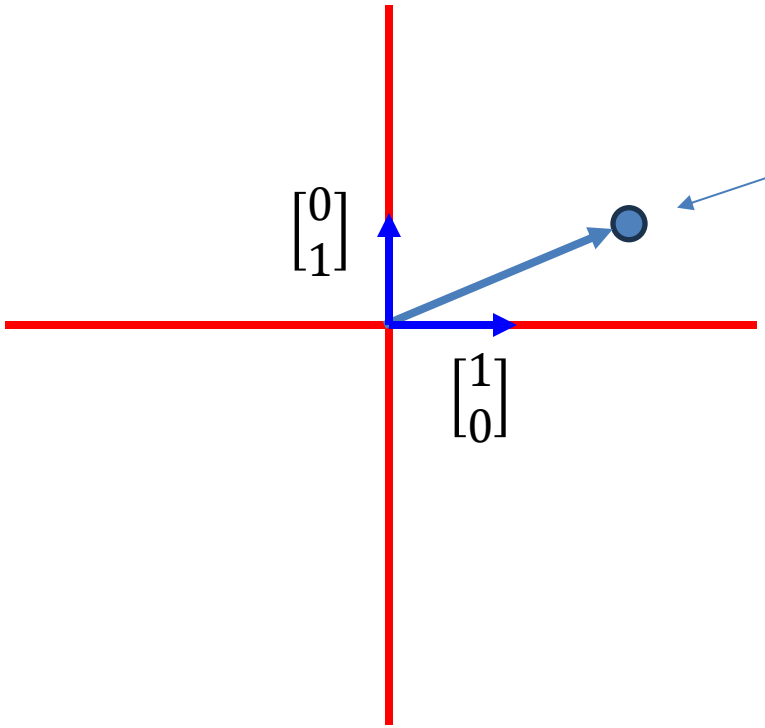

Misal, ini adalah vektor $\begin{bmatrix}2\\1\end{bmatrix}$ pada ruang dengan basis $\left\{\begin{bmatrix}1\\0\end{bmatrix}, \begin{bmatrix}0\\1\end{bmatrix}\right\}$.

Review Aljabar Linear

Dot product dapat digunakan untuk memproyeksikan sebuah vektor ke himpunan basis-basis yang **orthogonal** pada sebuah ruang vektor (untuk dapat koordinat).

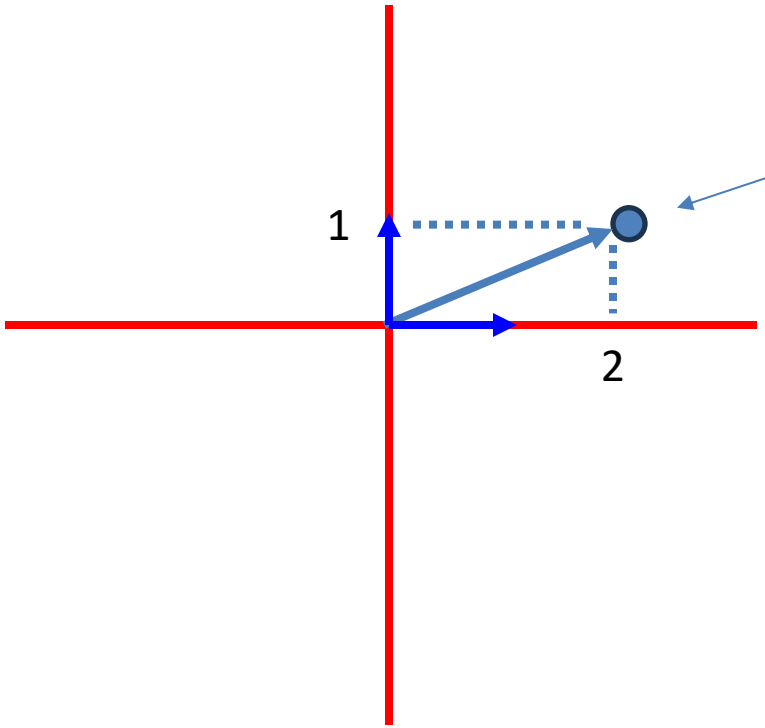

Misal, ini adalah vektor $\begin{bmatrix}2\\1\end{bmatrix}$ pada ruang dengan basis $\left\{\begin{bmatrix}1\\0\end{bmatrix}, \begin{bmatrix}0\\1\end{bmatrix}\right\}$.

$\begin{bmatrix}2\\1\end{bmatrix} \circ \begin{bmatrix}1\\0\end{bmatrix} = 2$ Koodinat di sumbu $\begin{bmatrix}1\\0\end{bmatrix}$

$\begin{bmatrix}2\\1\end{bmatrix} \circ \begin{bmatrix}0\\1\end{bmatrix} = 1$ Koodinat di sumbu $\begin{bmatrix}0\\1\end{bmatrix}$

Review Aljabar Linear

Dot product dapat digunakan untuk memproyeksikan sebuah vektor ke himpunan basis-basis yang **orthogonal** pada sebuah ruang vektor (untuk dapat koordinat).

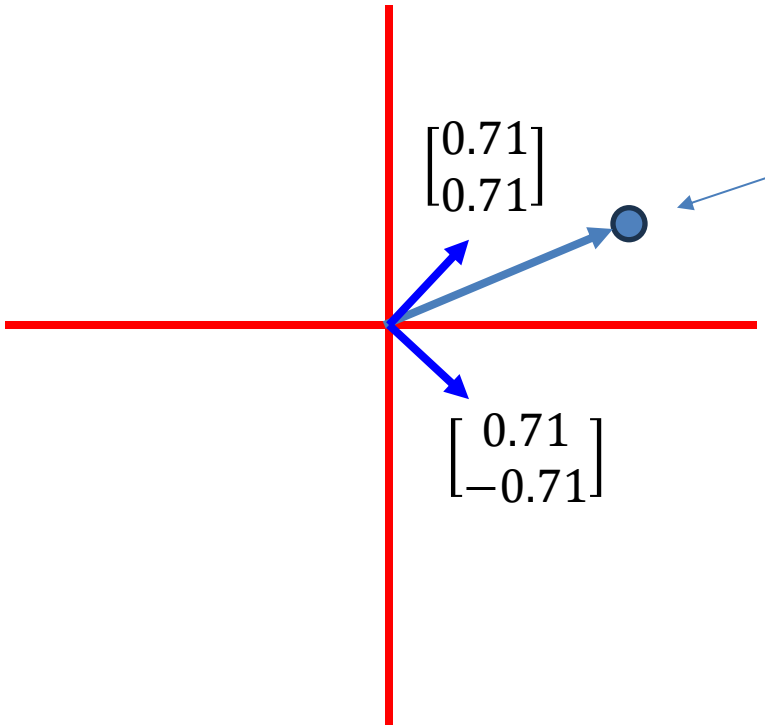

Sekarang, bagaimana posisi vektor ini terhadap basis yang baru?, yaitu

$$\left\{\begin{bmatrix}0.71\\0.71\end{bmatrix}, \begin{bmatrix}0.71\\-0.71\end{bmatrix}\right\}$$

Review Aljabar Linear

Dot product dapat digunakan untuk memproyeksikan sebuah vektor ke himpunan basis-basis yang **orthogonal** pada sebuah ruang vektor (untuk dapat koordinat).

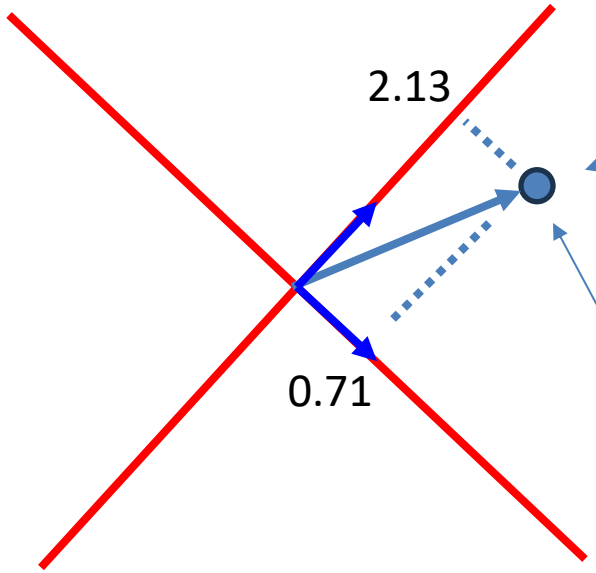

Sekarang, bagaimana posisi vektor ini terhadap basis yang baru, yaitu

$$\left\{\begin{bmatrix}0.71\\0.71\end{bmatrix}, \begin{bmatrix}0.71\\-0.71\end{bmatrix}\right\}$$

$$\begin{bmatrix}2\\1\end{bmatrix} \circ \begin{bmatrix}0.71\\0.71\end{bmatrix} = 2.13$$

$$\begin{bmatrix}2\\1\end{bmatrix} \circ \begin{bmatrix}0.71\\-0.71\end{bmatrix} = 0.71$$

ini adalah vektor $\begin{bmatrix}2.13\\0.71\end{bmatrix}$ di ruang yang baru ini

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

Kolom-kolom **U** saling **orthogonal** dan merupakan **basis baru** untuk **dokumen-dokumen (kolom pada C)** di ruang yang baru (hasil rotasi).

Jika **ini** adalah Vektor Dokumen **D2** di ruang vektor original, apa Vektor Dokumen **D2** di ruang vektor yang baru dengan basis adalah kolom-kolom pada **U**?

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0		

Kolom-kolom **U** saling **orthogonal** dan merupakan **basis baru** untuk **dokumen-dokumen (kolom pada C)** di ruang yang baru (hasil rotasi).

DOT PRODUCT!

Jika **ini** adalah Vektor Dokumen **D2** di ruang vektor original, apa Vektor Dokumen **D2** di ruang vektor yang baru dengan basis adalah kolom-kolom pada **U**?

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

Seperti yang sudah dipelajari pada review aljabar linear sebelumnya, ya sudah, Anda hanya perlu **dot-product** vektor original **D2** ke masing-masing 4 buah vektor basis pada kolom **U.**

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0		

Kolom-kolom **U** saling **orthogonal** dan merupakan **basis baru** untuk **dokumen-dokumen (kolom pada C)** di ruang yang baru (hasil rotasi).

DOT PRODUCT!

Jika **ini** adalah Vektor Dokumen **D2** di ruang vektor original, apa Vektor Dokumen **D2** di ruang vektor yang baru dengan basis adalah kolom-kolom pada **U**?

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

Seperti yang sudah dipelajari pada review aljabar linear sebelumnya, ya sudah, Anda hanya perlu **dot-product** vektor original **D2** ke masing-masing 4 buah vektor basis pada kolom **U; secara aljabar, vektor dokumen pada dimensi baru adalah kolom-kolom pada:**

$$U^T C$$

C

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0		

Kolom-kolom **U** saling **orthogonal** dan merupakan **basis baru** untuk **dokumen-dokumen (kolom pada C)** di ruang yang baru (hasil rotasi).

DOT PRODUCT!

Jika **ini** adalah Vektor Dokumen **D2** di ruang vektor original, apa Vektor Dokumen **D2** di ruang vektor yang baru dengan basis adalah kolom-kolom pada **U**?

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

Seperti yang sudah dipelajari pada review aljabar linear sebelumnya, ya sudah, Anda hanya perlu **dot-product** vektor original **D2** ke masing-masing 4 buah vektor basis pada kolom **U; secara aljabar, vektor dokumen pada dimensi baru adalah kolom-kolom pada:**

Kolomnya sekarang itu ada document embeeding

$$U^T C = \Sigma V^T$$

Sama saja dengan kolom-kolom pada $\mathbf{V^T}$, yang kemudian dikali bobot singular value pada topik yang bersesuaian.

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

C

Apakah kolom pada V^T juga merupakan **Document Embedding**?

Kolom pada V^T sebenarnya bisa juga "dianggap" sebagai vektor "baru" dari sebuah dokumen di ruang vektor baru; tapi ini adalah versi yang **UNWEIGHTED**, atau versi yang belum dikali dengan bobot topik Σ.

document embeeding yang weighted ada di U^T C atau SIGMA * V^T

Tapi kalau document embeedng yang UNWEIGHTED ada di V^T

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

V^T

LSA: Low-rank approximation of C

Ada juga yang sebut LSI (Latent Semantic Indexing)

LSA (Latent Semantic Analysis)

Truncating **U, ∑, V^T** to **K dimensions** produces best possible **K** rank approximation of original matrix **C -> rank K approximation to C with the smallest error (Frobenius Norm)**

Nah tujuannya kita ingin mencari aproksimasi C yang misalnya Ranknya terbaik (yang paling deket sama C

Buang (jadikan nol) L - K singular values paling kecil di ∑!

$U, \mathrm{M} \times L$

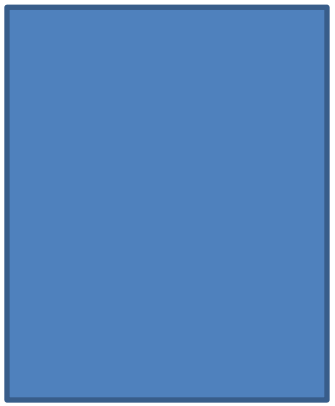

M = term

$\Sigma, L \times L$

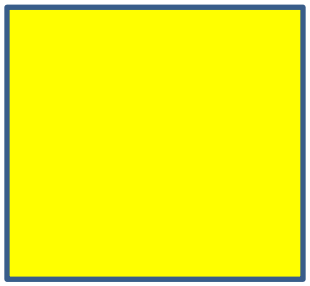

$V^T, L \times N$

N = dokumen

C_k = rank-k approximation of C

Truncating **U, ∑, V^T** to **K dimensions** produces best possible **K** rank approximation of original matrix **C.**

Jadikan NOL L - K singular values paling kecil di ∑!

basically dibuang L-K (kita mau ilangin Sigma kita jadi cuman K terbesar aja

$U_k, \mathrm{M} \times K$

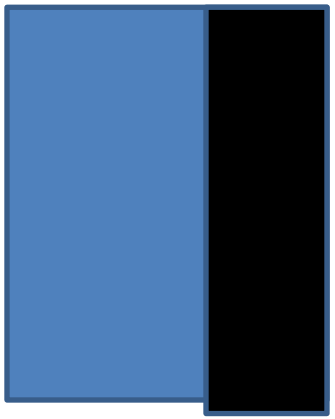

$\Sigma_k, K \times K$

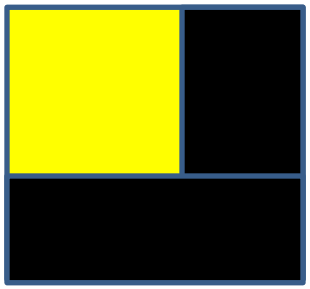

$V_k^T, K \times N$

$$C_k = U_k \times \Sigma_k \times V_k^T$$

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

C

Σ

18.93	0	0	0
0	14.49	0	0
0	0	2.60	0
0	0	0	0.86

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

U

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

V^T

← **truncated**

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

Contoh: rank-2 approximation of C

	D1	D2	D3	D4	D5
Cancer	6.27	0.76	9.03	0.29	7.85
Flower	1.80	7.99	0.65	9.04	0.57
Tumor	5.70	1.15	8.09	0.79	7.03
Rose	1.29	6.08	0.38	6.89	0.33

C_2

C_2 adalah matriks **Rank-2** yang paling kecil error-nya dengan **C**.

LSA = SVD yang kita ambil K yang terbesar. Nah gunanya untuk reduksi dimensi

18.93	0
0	14.49

Σ_2

	1	2
Cancer	0.66	0.33
Flower	0.33	-0.71
Tumor	0.61	0.25
Rose	0.24	-0.55

U_2

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26

V_2^T

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

Jadi mengapa LSA/SVD berhasil menangkap “similarity” antar kata?

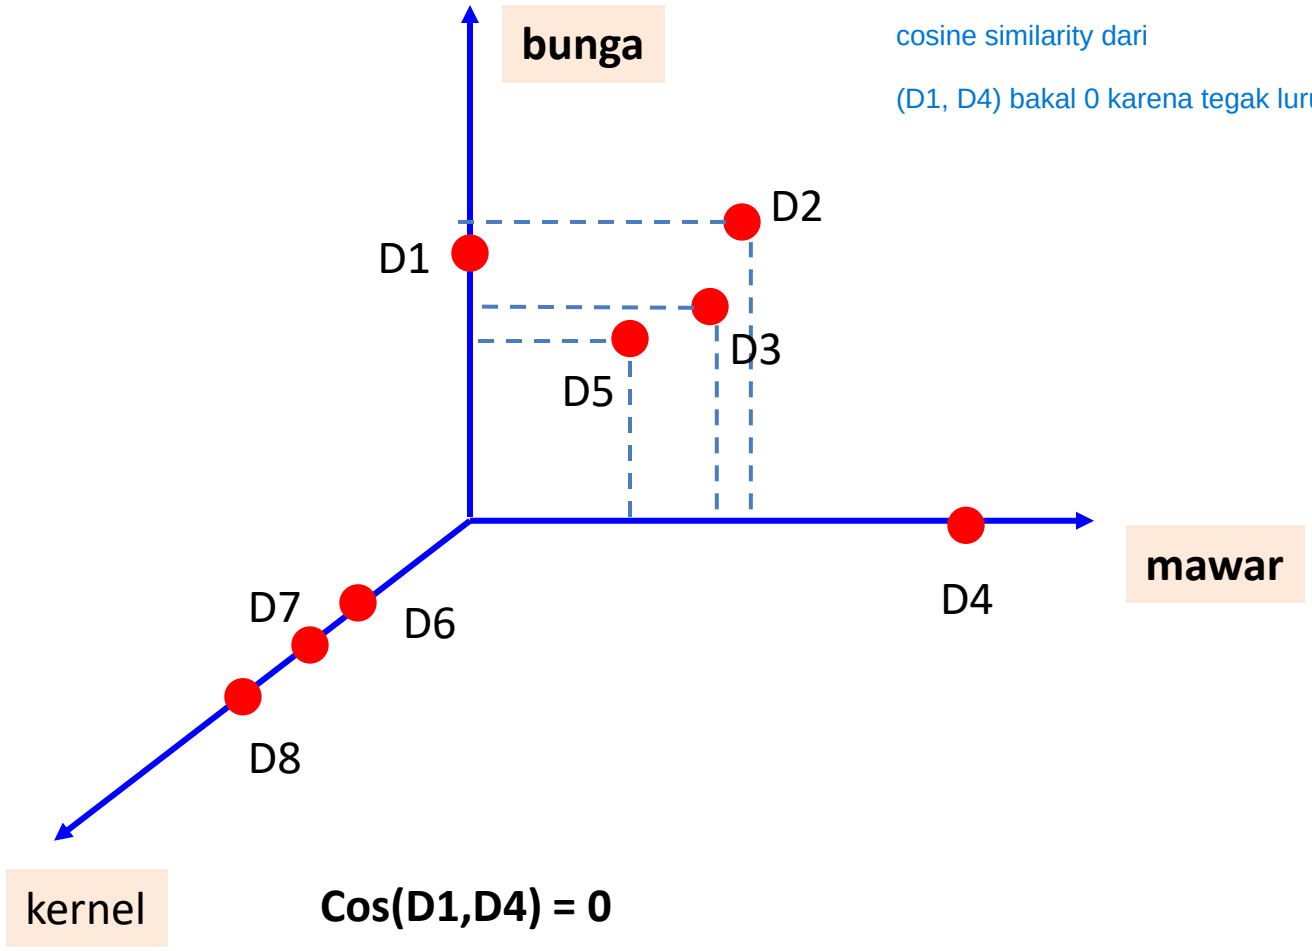

Cos(D1,D4) = 0

Padahal “bunga” dan “mawar” secara semantic “dekat”

Jadi mengapa LSA/SVD berhasil menangkap “similarity” antar kata?

Axis Rotation (via SVD)

Axis “kernel” tidak perlu dirotasi karena sudah berada pada variansi terbesar

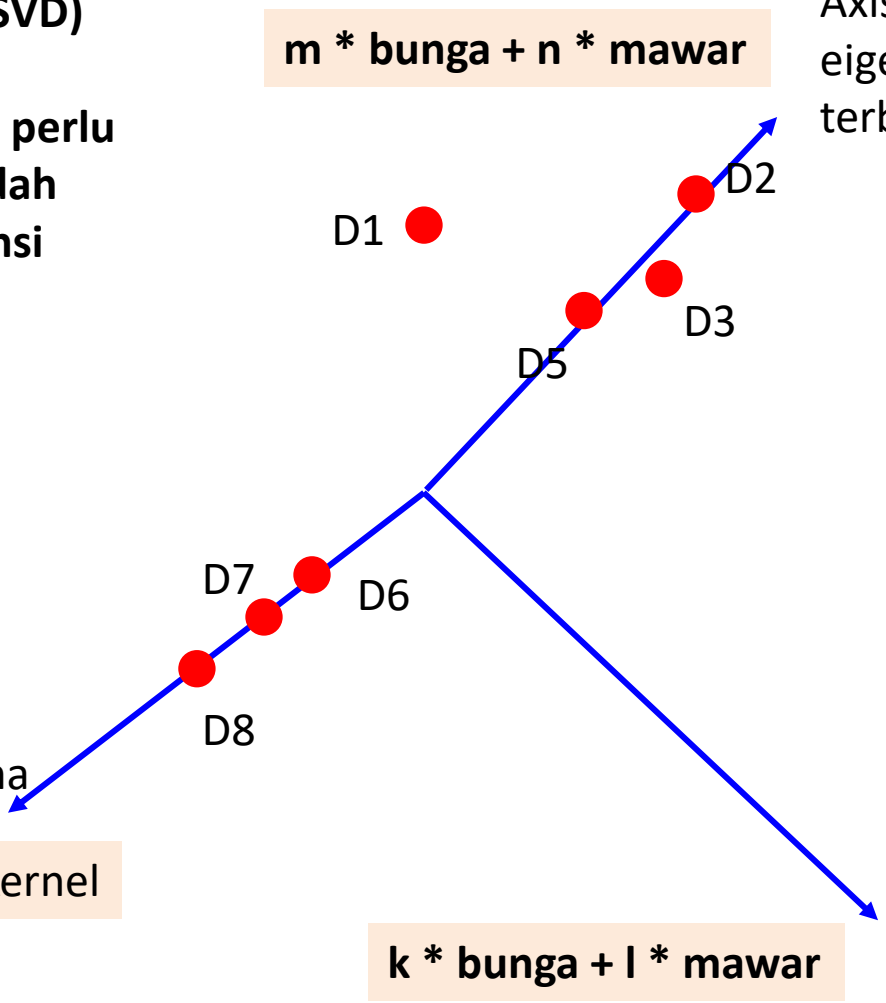

dirotate untuk variansi terbesar (atau fit dengan data-data yang ada)

Di LSA kita buang yang eigen value paling jelek (eigen value paling kecil).

Nah artinya dibuang, dari 3D jadi 2D

Jadi mengapa LSA/SVD berhasil menangkap “similarity” antar kata?

Buang Axis dengan eigenvalue paling kecil.

Akibatnya D1 & D4 berada pada axis yang sama, yaitu axis gabungan “bunga” dan “mawar”.

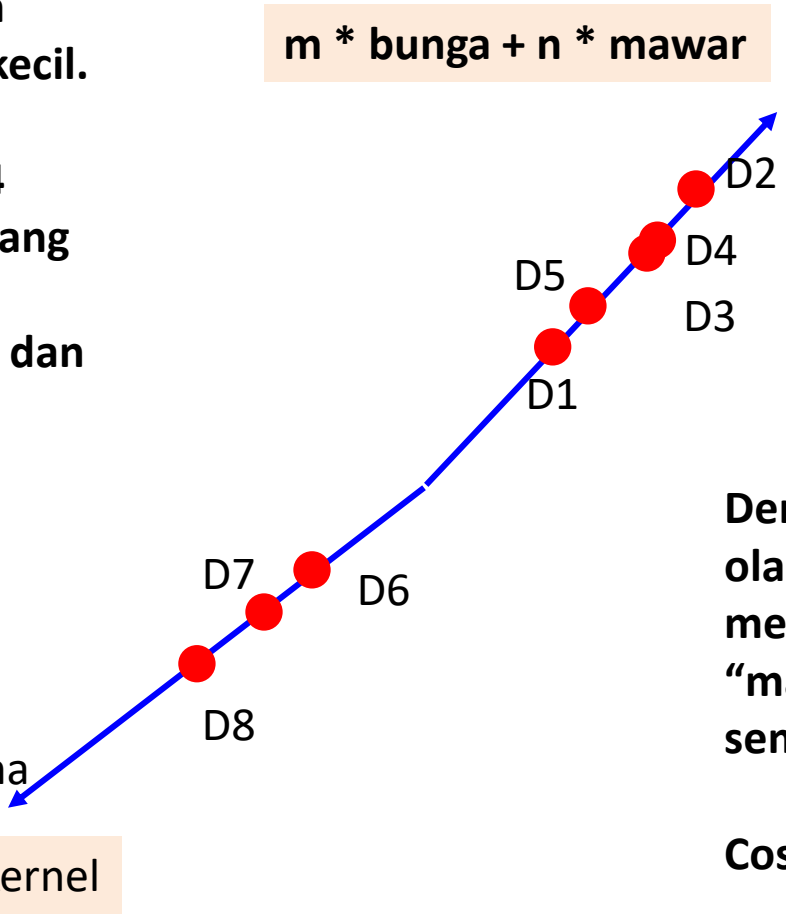

Nah tadi D1 dan D4 dirapetin karena dimensinya dikurangin. Oleh karena itu, Cos (D1, D4) sekarang gak 0 lagi

Dengan begitu, seolah-olah LSA/SVD berhasil menemukan “bunga” dan “mawar” dekat secara semantik.

Cos(D1, D4) > 0

Dimanakah *Document Vector*?

Jika ingin mendapatkan **rank-k vector representation** dari sebuah dokumen di **original vector space**:

=> Vektor kolom pada C_k

Dari Contoh sebelumnya:

	D1	D2	D3	D4	D5
Cancer	6.27	0.76	9.03	0.29	7.85
Flower	1.80	7.99	0.65	9.04	0.57
Tumor	5.70	1.15	8.09	0.79	7.03
Rose	1.29	6.08	0.38	6.89	0.33

C_2

Rank-2 Document Embedding dari D3 = [9.03, 0.65, 8.09, 0.38]

Dimanakah *Document Vector*?

Jika ingin mendapatkan **rank-k vector representation** dari sebuah dokumen di **vector space baru (rank-k subspace)**:

kalo di weighted

kalo unweighted ada di V^T

=> Vektor kolom pada $\boldsymbol{\Sigma_k \times V_k^T}$

Document Vector yang versi **"unweighted"**.

Dari Contoh sebelumnya:

2-Dimensional Document Embedding dari D3 adalah

Σ_2

18.93	0
0	14.49

$\times$ V_2^T

D3
0.59
0.30

$=$

D3
11.17
4.35

Dimanakah *Term Vector (Word Embedding)*?

Jika ingin mendapatkan **rank-k vector representation** dari sebuah kata di **vector space baru (rank-k subspace)**:

ini kalau weighted

kalo unweighted ada di U

=> Vektor baris pada $U_k \times \Sigma_k$

Term Vector yang versi **"unweighted"**.

Dari Contoh sebelumnya:

2-Dimensional Document Embedding dari "Cancer" adalah

Cancer	0.66	0.33

$\times$ Σ_2

18.93	0
0	14.49

$=$

Cancer	12.49	4.78

Jika ada Query, bagaimana hitung sim(Q, D)?

Vektor **Query** yang masih berada di dimensi awal perlu dipetakan ke **LSA (Semantic) Space** yang berukuran **K** dengan cara:

$$q_k = U_k^T \times q$$

Biasanya cosine similarity

$$sim(q, d) = sim(q_k, d_k)$$

Vektor kolom pada $\boldsymbol{\Sigma_k \times V_k^T}$ yang terasosiasi dengan **d (jika ada);** atau dokumen lain yang juga ditransformasi dengan cara yang sama.

Jika ada Query, bagaimana hitung sim(Q, D)?

Alternatif lain: seandainya kita mengasumsikan $\boldsymbol{q}$ adalah versi yang ***unweighted*** atau ***normalized***:

$$q_k = \Sigma_k^{-1} \times U_k^T \times q$$

Biasanya cosine similarity

$$sim(q, d) = sim(q_k, d_k)$$

Vektor kolom pada $\boldsymbol{V_k^T}$ yang terasosiasi dengan **d (jika ada);** atau dokumen lain yang juga ditransformasi dengan cara yang sama.

Contoh Soal LSA

Diberikan **Term-Document Matrix C** berikut dan hasil **SVD**-nya:

vektor dokumen ada di
- weighted Sigma V^T
- unweighted V^T

C

	D1	D2	D3
Bunga	2	1	0
Mawar	0	2	0
Kadal	0	0	3

Σ

	T1	T2	T3
T1	3	0	0
T2	0	2.56	0
T2	0		1.56

U

	T1	T2	T3
Bunga	0	0.78	-0.61
Mawar	0	0.61	0.78
Kadal	1	0	0

V^T

	D1	D2	D3
T1	0	0	1
T2	0.61	0.78	0
T3	-0.78	0.61	0

A) Diberikan sebuah **Query = "mawar mawar"**; manakah yang relevansinya lebih tinggi antara **D1** dan **D3** pada **ruang vektor original**?

B) Dengan Query yang sama manakah yang relevansinya lebih tinggi antara **D1** dan **D3** pada **ruang vektor "Rank-2" (i.e., Latent Semantic Indexing)**?

C) Hitunglah cosine similarity antara Query sebelumnya dengan dokumen baru **D4 = {"Bunga", "Kadal"}**!

Soal A) di ruang vektor original

$$Q = \begin{bmatrix} 0 \\ 2 \\ 0 \end{bmatrix} \qquad D_1 = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix} \qquad D_3 = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix}$$

$$sim(Q, D_1) = \frac{Q.D_1}{\|Q\|\|D_1\|} = 0$$

$$sim(Q, D_3) = \frac{Q.D_3}{\|Q\|\|D_3\|} = 0$$

D1 dan D3 sama-sama tidak mirip. **Make sense?**

Soal B) **Rank-2** Subspace

$$\Sigma_2 V_2^T = \begin{bmatrix} 0 & 0 & 3 \\ 1.57 & 2.01 & 0 \\ -1.23 & 0.96 & 0 \end{bmatrix}$$

dicoret

$$D_1' = \begin{bmatrix} 0 \\ 1.57 \end{bmatrix}$$

$$D_3' = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$$

$$Q' = U_2^T Q = \begin{bmatrix} 0 \\ 1.23 \end{bmatrix}$$

Sebagai bahan renungan, apa yang terjadi jika masih tetap pada **Rank-3 Subspace**? Apakah **sim(Q, D1) juga > 0**? Mengapa?

$$sim(Q', D_1') = \frac{Q'.D_1'}{\|Q'\|\|D_1'\|} = \frac{1.93}{1.23 \times 1.57} = 1$$

$$sim(Q', D_3') = \frac{Q'.D_3'}{\|Q'\|\|D_3'\|} = 0$$

D1 mirip dengan Q; D3 tidak

Soal B) **Rank-2** Subspace (cara alternatif, **unweighted vector**)

$$V_2^T = \begin{bmatrix} 0 & 0 & 1 \\ 0.61 & 0.78 & 0 \\ -0.78 & 0.61 & 0 \end{bmatrix}$$

dicoret

$$D_1' = \begin{bmatrix} 0 \\ 0.61 \end{bmatrix}$$

$$D_3' = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$Q' = \Sigma^{-1} U_2^T Q = \begin{bmatrix} 0 \\ 0.48 \end{bmatrix}$$

$$sim(Q', D_1') = \frac{Q'.D_1'}{\|Q'\|\|D_1'\|} = \frac{0.293}{0.48 \times 0.61} = 1$$

$$sim(Q', D_3') = \frac{Q'.D_3'}{\|Q'\|\|D_3'\|} = 0$$

D1 mirip dengan Q; D3 tidak

Soal C) **Silakan kerjakan sendiri untuk Latihan (500 Point)**

Uji Pemahaman Terhadap LSA

Refleksi

- Apa arti “distributional” pada “distributional word representations”?
- Apa itu “sparse word representations”? Apa contohnya?
- Apa itu “dense word representations”? Apa kelebihannya?
- Apa itu term-document matrix? Apa saja yang dapat digunakan untuk mengisi setiap cell pada matrix tersebut?

Refleksi

Misal, kita melakukan **Singular Value Decomposition** terhadap term-document matrix C (berukuran M x N):

$$C = U \times \Sigma \times V^T$$

term topic matrix

- Informasi apa yang ada pada **U**?
- Informasi apa yang ada pada **Σ**? Apa makna singular values?
- Informasi apa yang ada pada $\mathbf{V^T}$?
- Bagaimana menghitung **U**, **Σ**, dan $\mathbf{V^T}$?
- Dimanakah *vector representation of words* berada?
- Bagaimana caranya mendapatkan *low-dimensional vector of words (dense)* berukuran **K (< min(M, N))**?
- Bagaimana caranya mendapatkan *low-dimensional vector of documents (dense)* berukuran **K (< min(M, N))**?

baris = Term
kolom = topic (basis baru yang terbuat/latent topic untuk DOKUMEN, peleburan topic tinggi dan topic berat)

matrix diagonal
- makna: seberapa penting topic yang ada

baris = latent topic (basis baru utk TERM)
kolom = dokumen

U = C C^T
V = C^T C

sigma = Akar dari eigen values

term embeeding di baris U
weighted U SIGMA

U ambil k docs dan potong sigma jadi k x k

mirip sama yang U tapi buat V

tujuan LSA: dokumen-dokumen yang mengandung kata-kata yang dekat, memiliki similarity yang tinggi.

LSA -> pakai SVD dan buang latent topic yang singular valuenya kecil. Kita sisakan aja singular value yang nilainya besar

Refleksi

Perhatikan Term-Document matrix berikut (setiap cell berisi informasi TF):

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

Sebenarnya apa sih yang dilakukan LSA?

When forced to squeeze the terms/documents down to a k-dimensional space, the SVD should bring to- gether terms with similar co-occurrences.

Refleksi

Perhatikan Term-Document matrix berikut (setiap cell berisi informasi TF):

Kira-kira ada berapa latent topics yang penting di sini?

	D1	D3	D5	D2	D4
Cancer	6	10	7	0	1
Tumor	6	7	8	2	0
Flower	2	1	0	8	9
Rose	1	0	1	6	7

LSA akan memindahkan term (baris) dan dokumen (kolom) **sehingga vektor-vektor yang mirip akan berdekatan (ter-cluster)**.

Setelah ter-cluster, LSA kemudian bisa menemukan, kira-kira ada berapa **“latent topics penting”** yang ada pada koleksi dokumen tersebut.

	D1	D2	D3	D4	D5
Cancer	6	0	10	1	7
Flower	2	8	1	9	0
Tumor	6	2	7	0	8
Rose	1	6	0	7	1

Itulah mengapa hanya ada 2 singular values yang sangat besar dibandingkan 2 yang terkecil.

18.93	0	0	0
0	14.49	0	0
0	0	2.60	0
0	0	0	0.86

	1	2	3	4
Cancer	0.66	0.33	0.64	0.18
Flower	0.33	-0.71	0.18	-0.57
Tumor	0.61	0.25	-0.72	-0.19
Rose	0.24	-0.55	-0.18	0.77

	D1	D2	D3	D4	D5
1	0.45	0.28	0.59	0.28	0.51
2	0.10	-0.59	0.30	-0.69	0.26
3	-0.11	-0.41	0.59	0.38	-0.56
4	-0.51	-0.42	-0.12	0.44	0.58
5	-0.70	0.46	0.42	-0.30	0.04

```
import numpy as np; u, s, vt = np.linalg.svd(C, full_matrices = True)
```

Simple Explanation of LSA

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

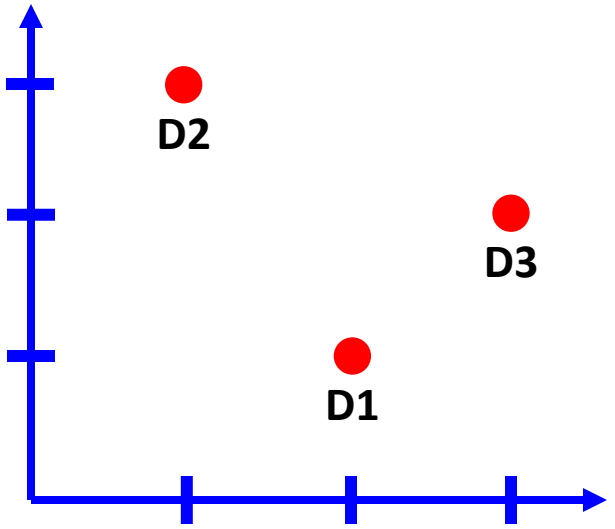

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

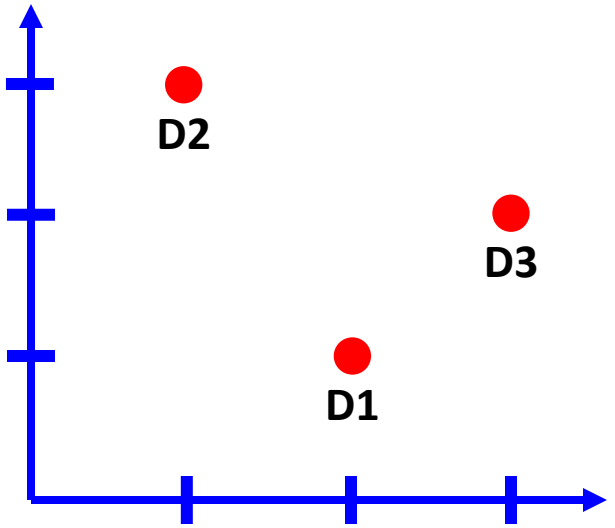

Misal, kita lakukan SVD:

$$U = \begin{bmatrix} 0.71 & -0.71 \\ 0.71 & 0.71 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 1.7 & 0 \end{bmatrix}$$

$$V^T = \begin{bmatrix} 0.42 & 0.57 & 0.71 \\ -0.41 & 0.82 & -0.41 \\ -0.81 & -0.11 & 0.57 \end{bmatrix}$$

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

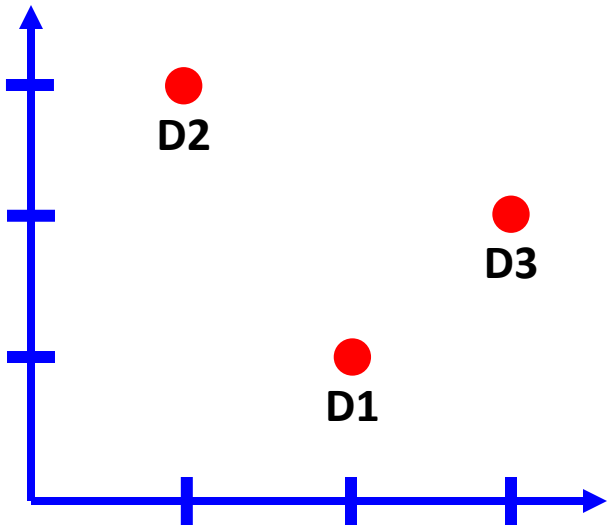

Rank-1 approximation dari C:

$$U = \begin{bmatrix} 0.71 & -0.71 \\ 0.71 & 0.71 \end{bmatrix}$$

$$\Sigma_1 = \begin{bmatrix} 5 & 0 & 0 \\ 0 & \mathbf{0} & 0 \end{bmatrix}$$

$$V^T = \begin{bmatrix} 0.42 & 0.57 & 0.71 \\ -0.41 & 0.82 & -0.41 \\ -0.81 & -0.11 & 0.57 \end{bmatrix}$$

$$C_1 = U \times \Sigma_1 \times V^T = \begin{bmatrix} 1.5 & 2 & 2.5 \\ 1.5 & 2 & 2.5 \end{bmatrix}$$

Misal, kita mempunyai term-document matrix berikut (bobot TF):

We move the points to **the smallest squared distance.**

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

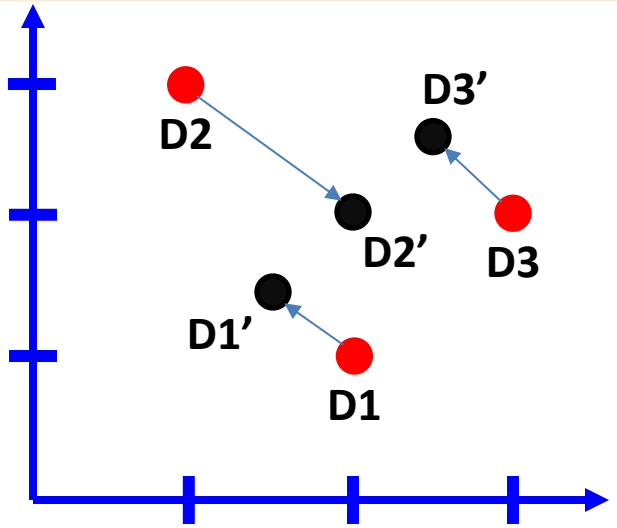

Rank-1 approximation dari C (Rank-1 Document Vector):

$$U = \begin{bmatrix} 0.71 & -0.71 \\ 0.71 & 0.71 \end{bmatrix}$$

$$\Sigma_1 = \begin{bmatrix} 5 & 0 & 0 \\ 0 & \mathbf{0} & 0 \end{bmatrix}$$

$$V^T = \begin{bmatrix} 0.42 & 0.57 & 0.71 \\ -0.41 & 0.82 & -0.41 \\ -0.81 & -0.11 & 0.57 \end{bmatrix}$$

$$C_1 = U \times \Sigma_1 \times V^T = \begin{bmatrix} 1.5 & 2 & 2.5 \\ 1.5 & 2 & 2.5 \end{bmatrix}$$

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

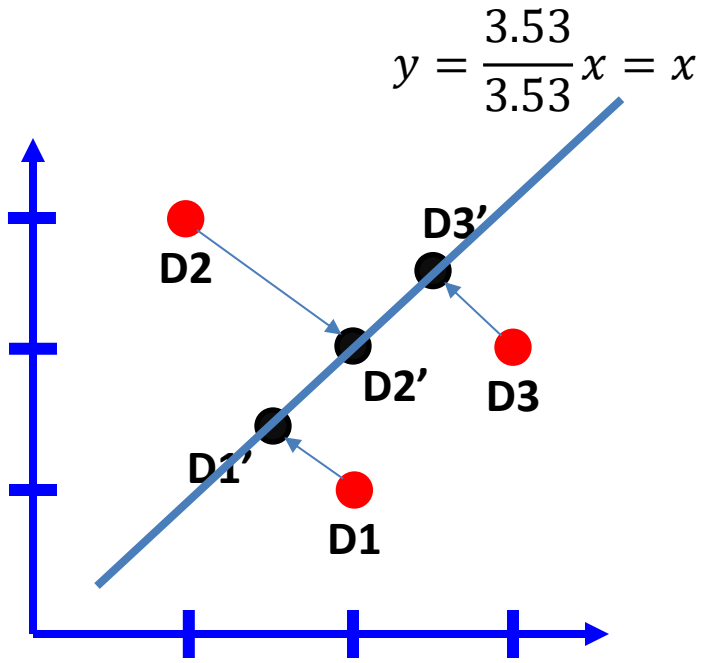

Vektor Kata:

$$U \times \Sigma_1 = \begin{bmatrix} 3.53 & 0 & 0 \\ 3.53 & 0 & 0 \end{bmatrix}$$

$$C_1 = U \times \Sigma_1 \times V^T = \begin{bmatrix} 1.5 & 2 & 2.5 \\ 1.5 & 2 & 2.5 \end{bmatrix}$$

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

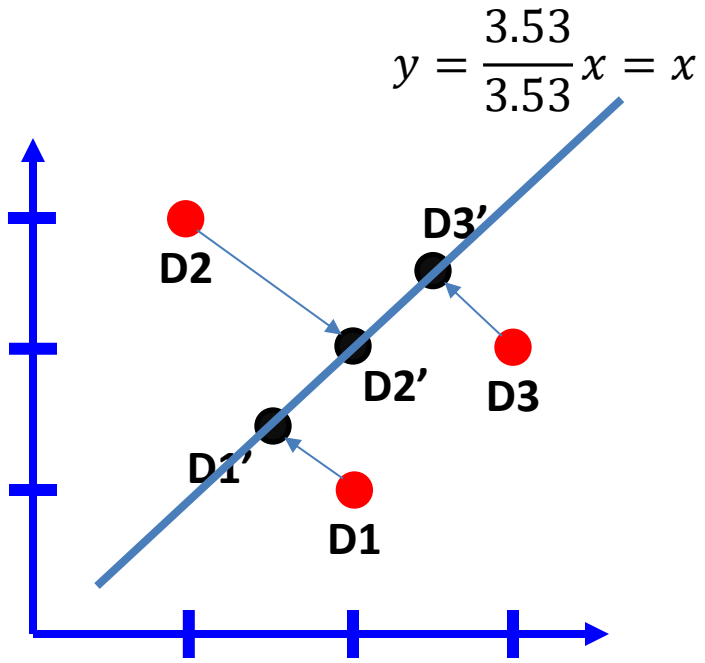

Vektor Dokumen di Space Dim = 1:

$$\Sigma_1 \times V^T = \begin{bmatrix} 2.1 & 2.8 & 3.5 \\ 0 & 0 & 0 \end{bmatrix}$$

$$C_1 = U \times \Sigma_1 \times V^T = \begin{bmatrix} 1.5 & 2 & 2.5 \\ 1.5 & 2 & 2.5 \end{bmatrix}$$

Misal, kita mempunyai term-document matrix berikut (bobot TF):

$$C = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 3 & 2 \end{bmatrix}$$

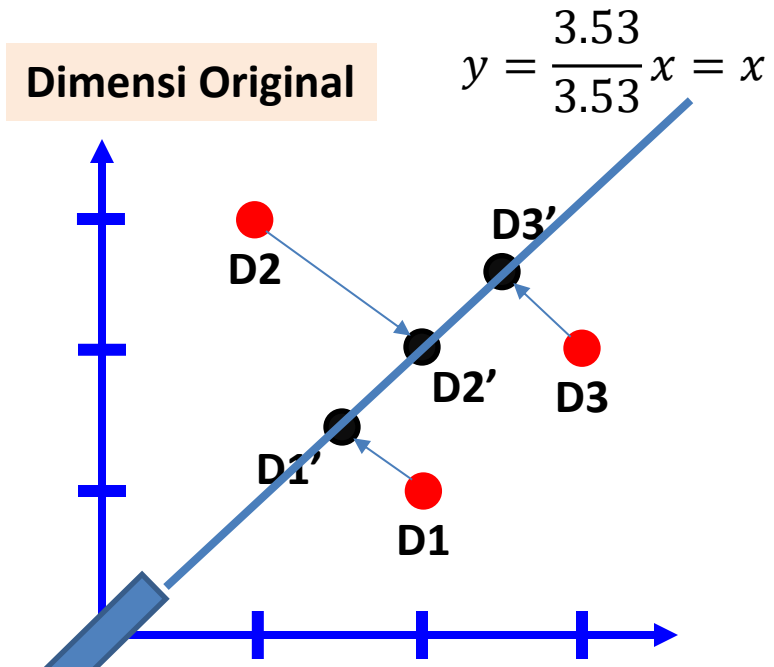

Vektor Dokumen di Space Dim = 1:

$$\Sigma_1 \times V^T = \begin{bmatrix} 2.1 & 2.8 & 3.5 \\ 0 & 0 & 0 \end{bmatrix}$$

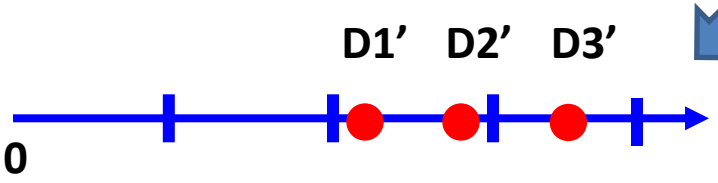

$$C_1 = U \times \Sigma_1 \times V^T = \begin{bmatrix} 1.5 & 2 & 2.5 \\ 1.5 & 2 & 2.5 \end{bmatrix}$$

Neural Embeddings

Why Word Embeddings?

- Can capture the rich relational structure of the lexicon

kita bisa expand term term waktu user search query, misal kayak spain di expand madrid

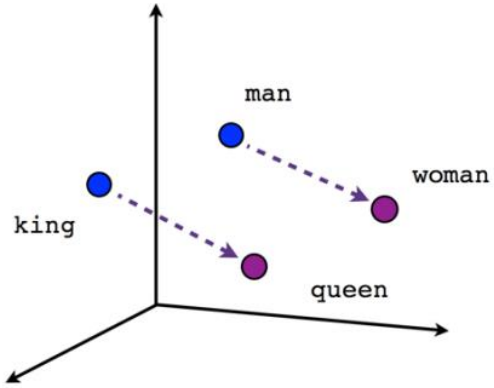

Male-Female

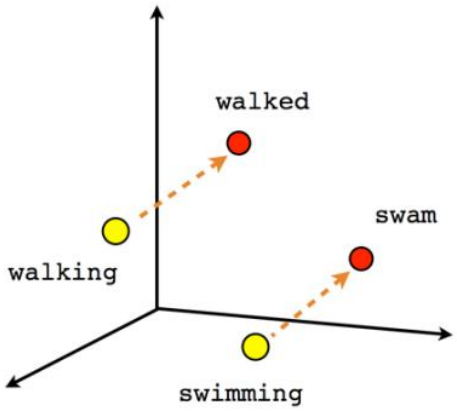

Verb tense

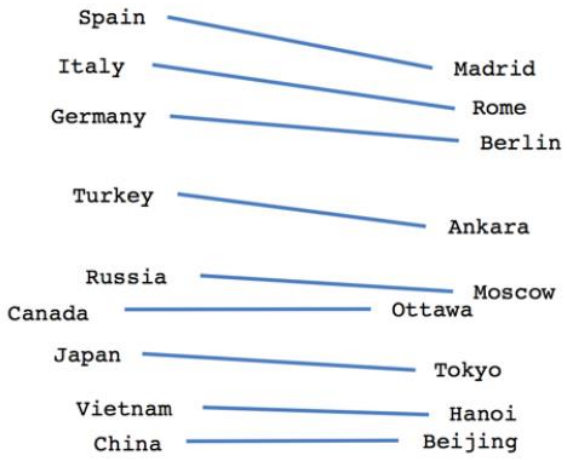

Country-Capital

https://www.tensorflow.org/tutorials/word2vec

Word Embeddings

- Any technique that maps a word (or phrase) from **it's original high-dimensional sparse input** space to **a lower-dimensional dense vector space**.

- Vectors whose relative similarities correlate with semantic similarity

- Such vectors are used both as an end in itself (for computing similarities between terms), and as a representational basis for downstream NLP tasks, such as POS tagging, NER, text classification, etc.

Continuous Representation of Words

The Differences:

- In **information retrieval,** LSA and topic models use ***documents as contexts***.
  - Capture semantic relatedness (**"boat" and "water"**)

- **Distributional semantic models** use ***words as contexts*** (more natural in linguistic perspective)
  - Capture semantic similarity **("boat" and "ship")**

Word Embedding

DSMs or Word Embeddings

- Count-based model
  - first collecting context vectors and then reweighting these vectors based on various criteria

word embeeding berbeasis neural network

- Predictive-based model (neural network)
  - vector weights are directly set to optimally predict the contexts in which the corresponding words tend to appear
  - Similar words occur in similar contexts, the system naturally learns to assign similar vectors to similar words.

Distributional Semantic Models

Other classification based on (Baroni et al., ACL 2014)

- Count-based models
  - Simple VSMs
  - Singular Value Decomposition (Golub & VanLoan, 1996)
  - Non-negative Matrix Factorization (Lee & Seung, 2000)
- Predictive-based models (**neural network**)
  - Self Organizing Map
  - Bengio et al's **Word Embedding (2003)**
  - Mikolov et al's **Word2Vec (2013)**

Baroni et la., "Don't count, predict! A systematic comparison of context-counting vs. context-predicting semantic vectors". ACL 2014

Word Analogy Task

- **Father** is to **Mother** as **King** is to _____ ?
- **Good** is to **Best** as **Smart** is to _____ ?
- **Indonesia** is to **Jakarta** as **Malaysia** is to ____ ?

- It turns out that the previous Word-Context based vector model is good for such analogy task.

$$V_{king} - V_{father} + V_{mother} = V_{queen}$$

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Distributed Representations of Words and Phrases and their Compositionality. NIPS, 1–9

Word2Vec (Mikolov et al., 2013)

Word2Vec

- One of the most popular Word Embedding models nowadays!
- There are two types of models:
  - Skip-Gram Model
  - Continuous Bag of Words Model (**CBOW**)

Causal Language Modeling: pakai RNN, NN

kalau kita kaitkan skipgram dengan neural network, maka akan ada side effect yaitu Word Embeeding. Ini beda dengan Causal Language Modeling

Skip-Gram

- **N-Gram language model** only looks at previous words as a context for predictions.

jadi lihat context dari sebelumnya aja (kata-kata sebelumnya)

- This model tries to maximize classification of a word based on another word in the same sentence.

- Use each current word as an input to a log-linear classifier with continuous projection layer, and predict words within a certain range before and after the current word.

We seek a model for

$$P(w_{t+j} \mid w_t)$$

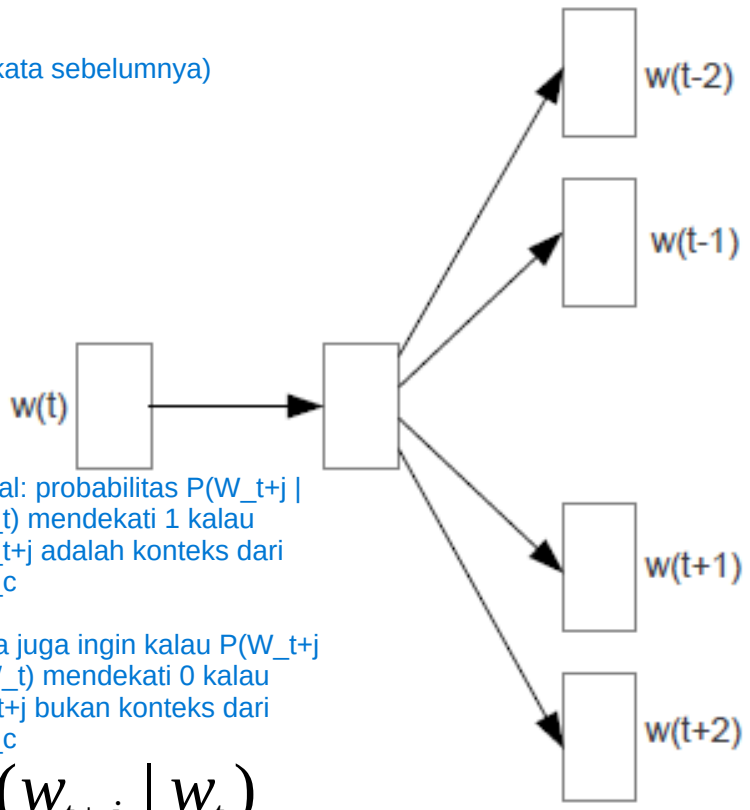

Goal: probabilitas P(W_t+j | W_t) mendekati 1 kalau W_t+j adalah konteks dari W_c

Kita juga ingin kalau P(W_t+j | W_t) mendekati 0 kalau w_t+j bukan konteks dari W_c

nah ini bisa pakai skip-gram

W_t+j itu context
Wt nya itu sebagai center

Skip-Gram

ini apporach menggunakan NN (neural network)

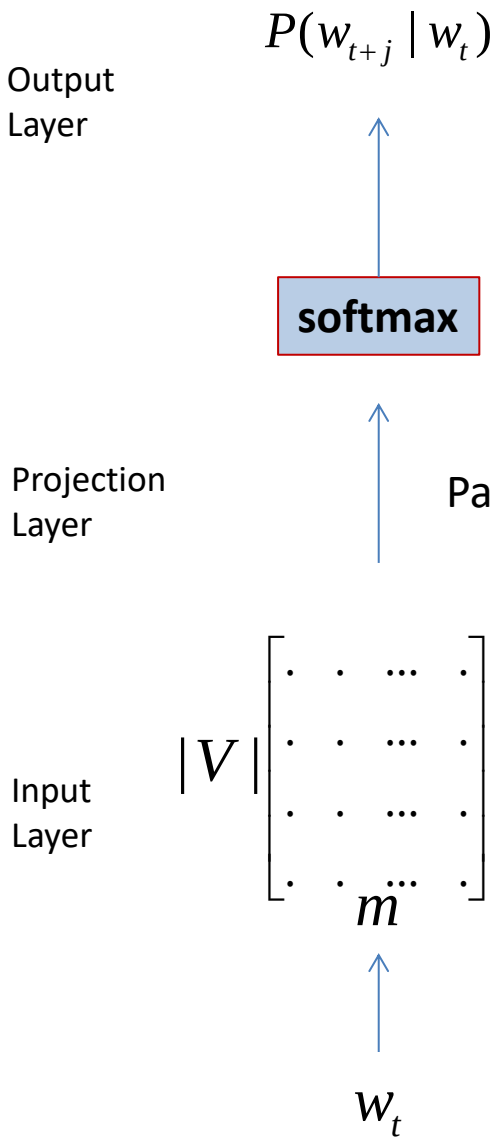

Feed-Forward Process

$$P(w_{t+j} \mid w_t) = \frac{\exp(y_{w_{t+j}})}{\sum_{i \in V} \exp(y_i)}$$

$$\boldsymbol{y_{w_t} = W.x}$$

$$x = C(w_t)$$

Total Parameters:

$$\theta = \{W, C\}$$

$$C \in R^{|V| \times m}$$

$$W \in R^{m \times |V|}$$

Skip-Gram

Sudut Pandang Lain

Sebuah kata **t** terasosiasi dengan dua buah vector:

- Vector ketika **t** berperan sebagai **center word** (baris pada matriks $\boldsymbol{C}$)
- Vector ketika **t** berperan sebagai **context word** (kolom pada matriks $\boldsymbol{W}$)

Skip-Gram

word embeeding tumor ada 2 pendekatan:
- ada yang pakai matrix center aja sebagai word embeeding
- ada juga pendekatan lain, yaitu rata-rata embeeding C dan rata-rata di matrix W (context word)

Sudut Pandang Lain

Misal Vocab = [cancer, tumor, flower, rose]

|Vocab| X |Embeeding Dimension|

Matriks C

Center word

embeddings of tumor

setiap baris maksudnya word embeeding

Low-dimensional Dense Embeddings of Tumor

$$\begin{bmatrix}0\\1\\0\\0\end{bmatrix}^T \times \begin{bmatrix}0.1 & 0.2 & 0.2\\ 0.1 & 0.1 & 0.3\\ 0.8 & 0.4 & 0.1\\ 0.9 & 0.3 & 0.1\end{bmatrix} = \begin{bmatrix}0.1\\0.1\\0.3\end{bmatrix}^T$$

berapa banyak kata di vocab
x
dimensi embeeding
(hyperparametercoba-coba)

One-hot representation of tumor

$$P(rose|tumor) = 0.25$$

|Embeeding Dimension| X |VOCAB|

Matriks W

Context word

embeddings of **rose**

$$softmax\left\{\begin{bmatrix}0.1\\0.1\\0.3\end{bmatrix}^T \times \begin{bmatrix}0.3 & 0.2 & 0.3 & 0.1\\ 0.2 & 0.2 & 0.4 & 0.7\\ 0.2 & 0.3 & 0.3 & 0.1\end{bmatrix}\right\} = \begin{bmatrix}0.24\\0.25\\0.26\\0.25\end{bmatrix}$$

yang di blue highlight:

adalah embeeding suatu kata sebagai CENTER

Skip-Gram

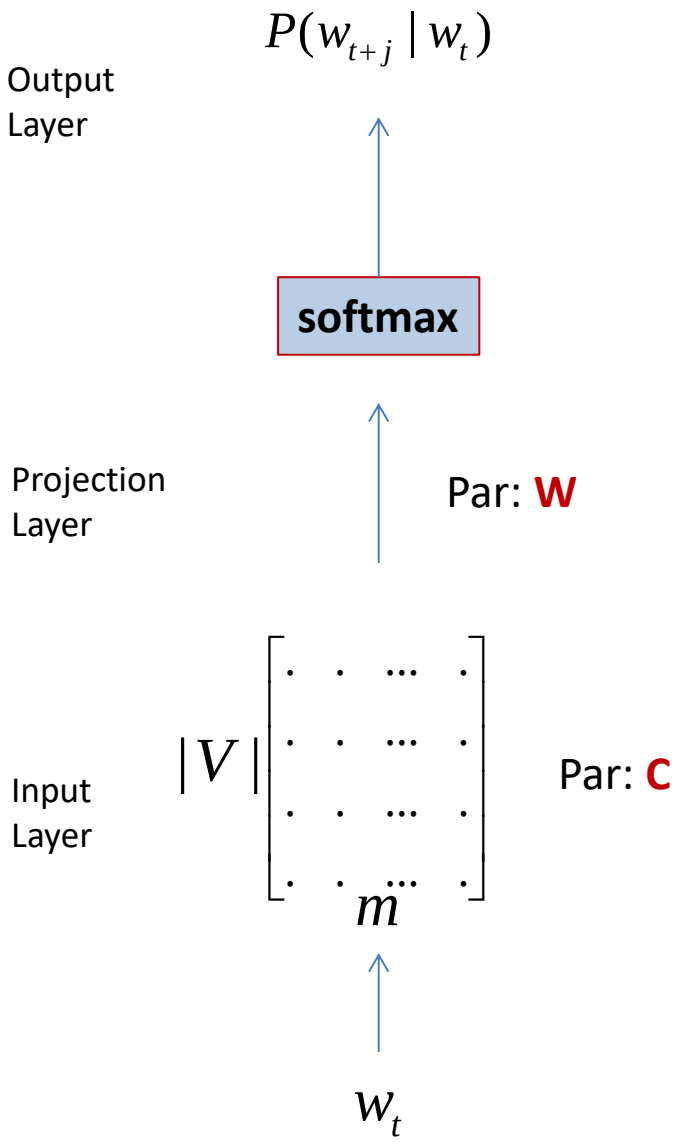

Dengan kata lain, Skip-Gram juga bisa dinyatakan dengan:

$$P(w_{t+j}|w_t) = \frac{exp(s(w_{t+j}, w_t))}{\sum_{i \in V} exp(s(w_i, w_t))}$$

$$s(w_i, w_t) = center(w_t)^T . context(w_i)$$

Baris di matriks C

Kolom di matriks W

Where are the Word Embeddings?

- The previous model actually aims at building the language model.
  - So, **where is the Word Embedding model that we need?**

- **The answer is:** If you just need the Word Embedding model, you just need the matrix **C**

Where are the Word Embeddings?

After all parameters (including **C**) are optimized, then we can use **C** to map a word into its vector !

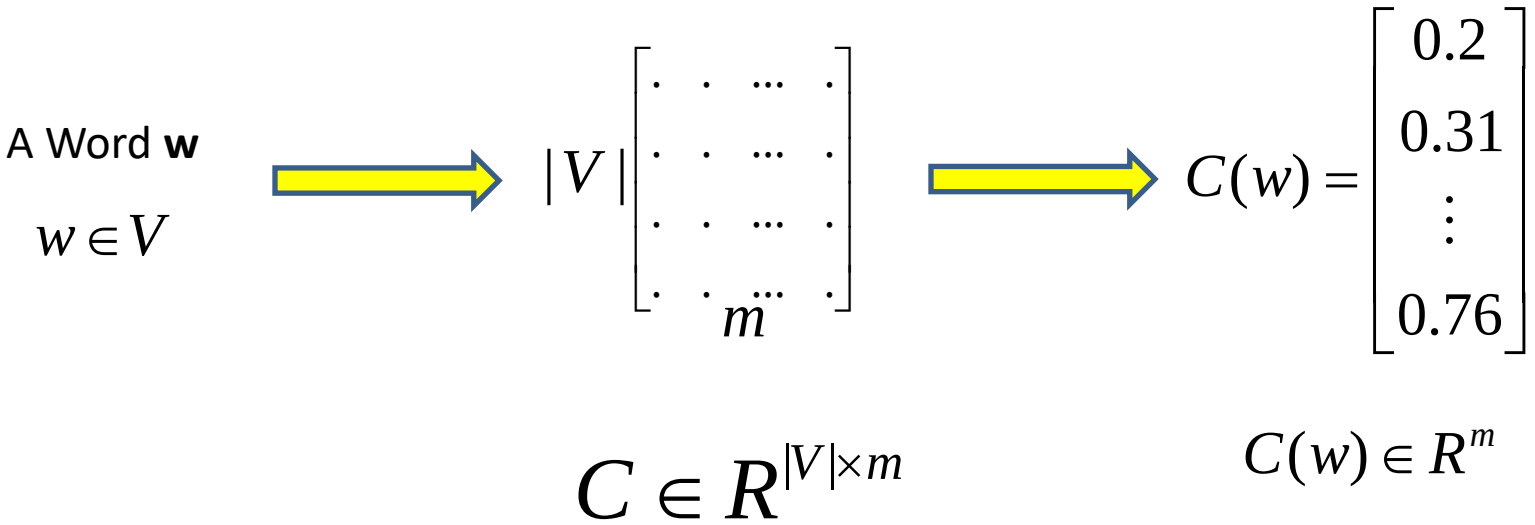

Skip-Gram

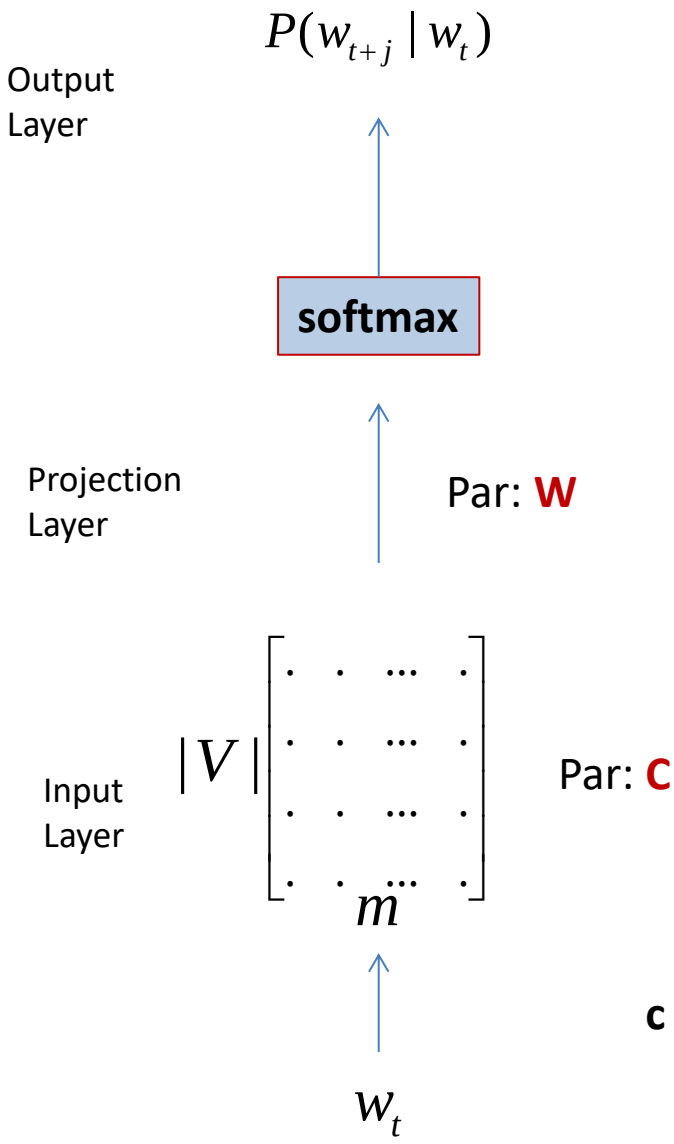

Training

Training is achieved by looking **θ** that maximizes the following Cost Function:

Given training data $w_1, w_2, w_3, \ldots, w_{T-1}, w_T$

$$J(w_1 \ldots w_T; \theta)$$

$$= \frac{1}{T} \sum_{t=1}^{T} \sum_{-c \le j \le c, j \neq 0} \log P(w_{t+j} \mid w_t) + R(\theta)$$

Regularization Terms

c is the maximum distance of the words, or **WINDOW size**

Skip-Gram

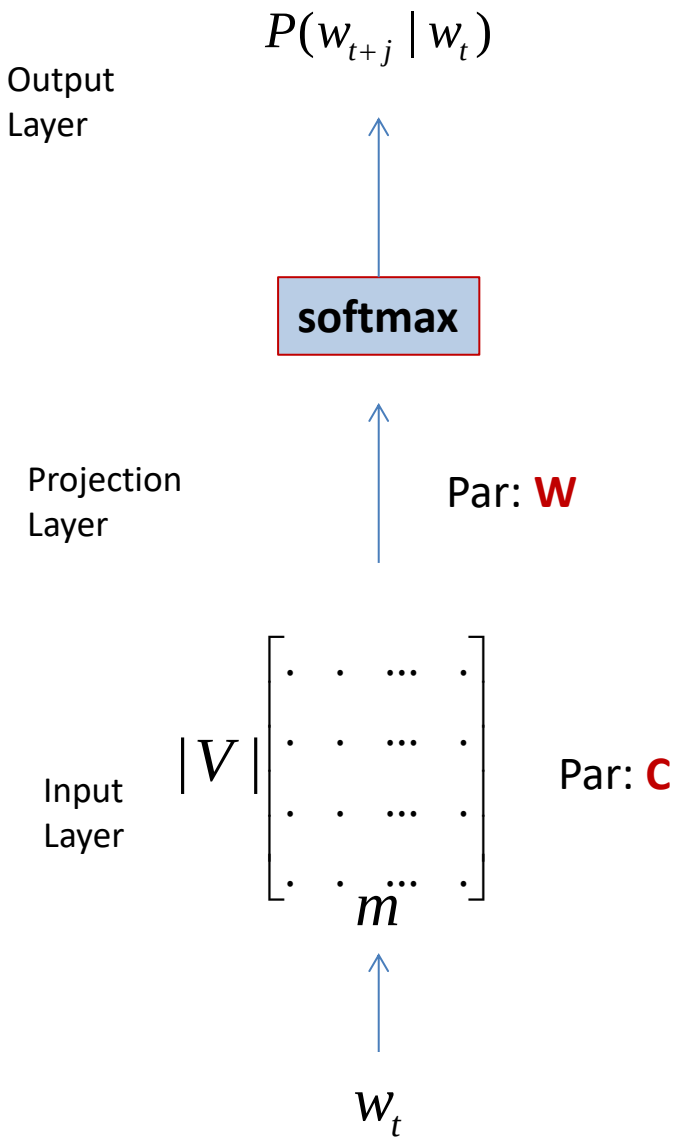

Training

Training is achieved by looking **θ** that maximizes the following Cost Function:

Given training data $w_1, w_2, w_3, \ldots, w_{T-1}, w_T$

$$J(w_1 \ldots w_T; \theta) = \frac{1}{T} \sum_{t=1}^{T} \sum_{-c \le j \le c, j \neq 0} \log P(w_{t+j} \mid w_t) + R(\theta)$$

Proses optimasi (memaksimalkan) fungsi J = menggunakan Categorical Cross Entropy sebagai loss function pada ujung softmax layer.

Reference: https://www.tensorflow.org/tutorials/word2vec

Skip-Gram

How to develop dataset?

For example, let's consider the following dataset:

the quick brown fox jumped over the lazy dog

Using **c = 1 (or window = 1)**, we then have dataset:

```
([the, brown], quick), ([quick, fox], brown), ([brown, jumped], fox), ...
```

Therefore, our **(input, output)** dataset becomes:

```
(quick, the), (quick, brown), (brown, quick), (brown, fox), ...
```

For example, $P(w_{t+1} = brown \mid w_t = quick)$

Use this dataset to learn $P(w_{t+j} \mid w_t)$

$$J(w_1 \ldots w_T; \theta) = \frac{1}{T} \sum_{t=1}^{T} \sum_{-c \le j \le c, j \ne 0} \log P(w_{t+j} \mid w_t)$$

So that, the cost function is optimized!

Skip-Gram

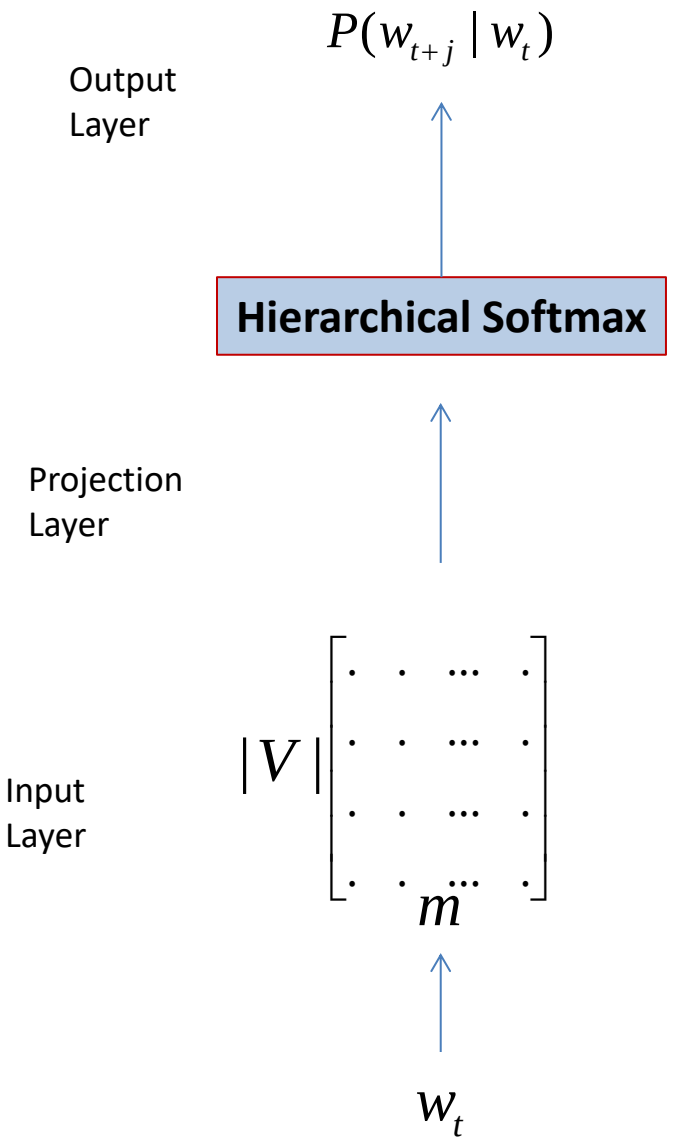

Training

Actually, if we use **vanilla softmax**, then the computational complexity **per instance** (**Q**) is still costly.

$$Q = D \times (m + m \times |V|)$$

D is the maximum distance of the words

biar komputasi softmax di ujung bisa lebih murah

To solve this problem, they use **Hierarchical Softmax layer**. This layer uses a **binary tree representation** of the output layer with |V| units.

$$Q = D \times (m + m \times \log_2 |V|)$$

(Morin & Bengio, 2005)

Hierarchical Softmax

- A **multi-layer binary tree**
- The probability of a word is calculated through the **product of probabilities on each edge on the path to that node**.
- It is **O(log n)**, compared to **O(n)** for vanilla softmax.

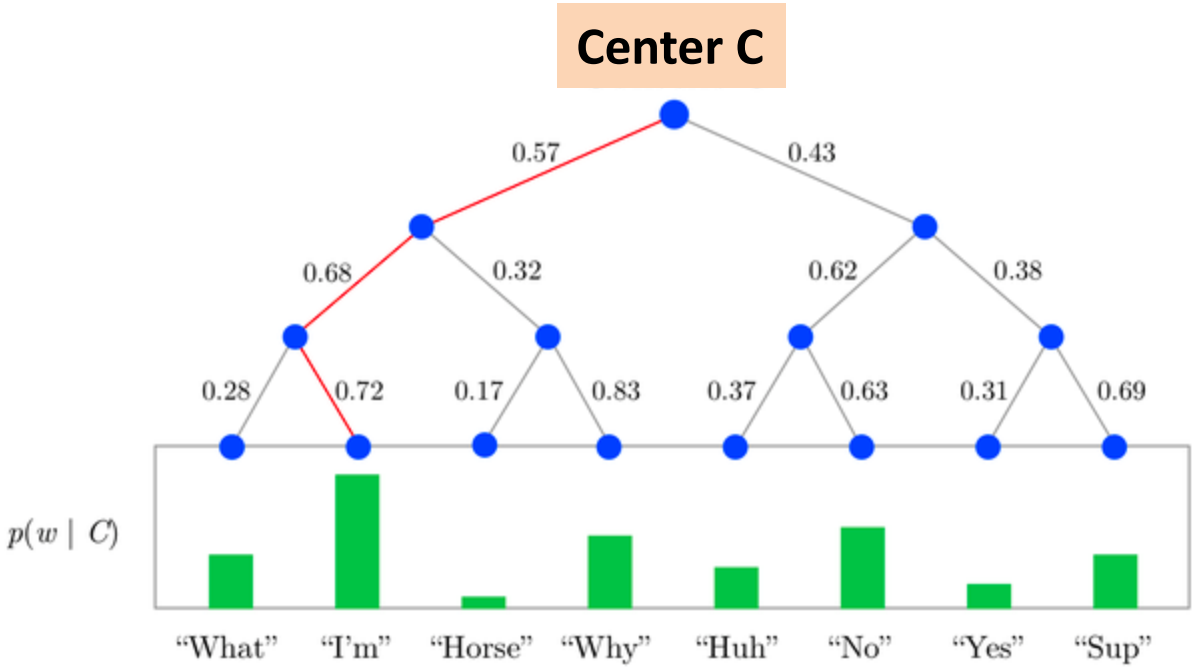

Hierarchical Softmax

- Misal, diberikan sebuah kata input **“kernel”** sebagai center, kita ingin memprediksi sebuah kata **konteks w**.
- Melakukan traversal Huffman Tree menggunakan kode binary yang diassign ke kata **w**.
- Perhitungan probability hanya melibatkan sekumpulan kecil node pada jalur root ke kata **w**.

Hierarchical Softmax

Huffman Tree

Meminimalkan expected search length

Gabung dua buah kata dengan frekuensi paling kecil; dan proses ini dilakukan terus.

kadal, 21 **mutex, 15** **os, 13** **kernel, 20**

Hierarchical Softmax

Huffman Tree

Gabung dua buah kata dengan frekuensi paling kecil; dan proses ini dilakukan terus.

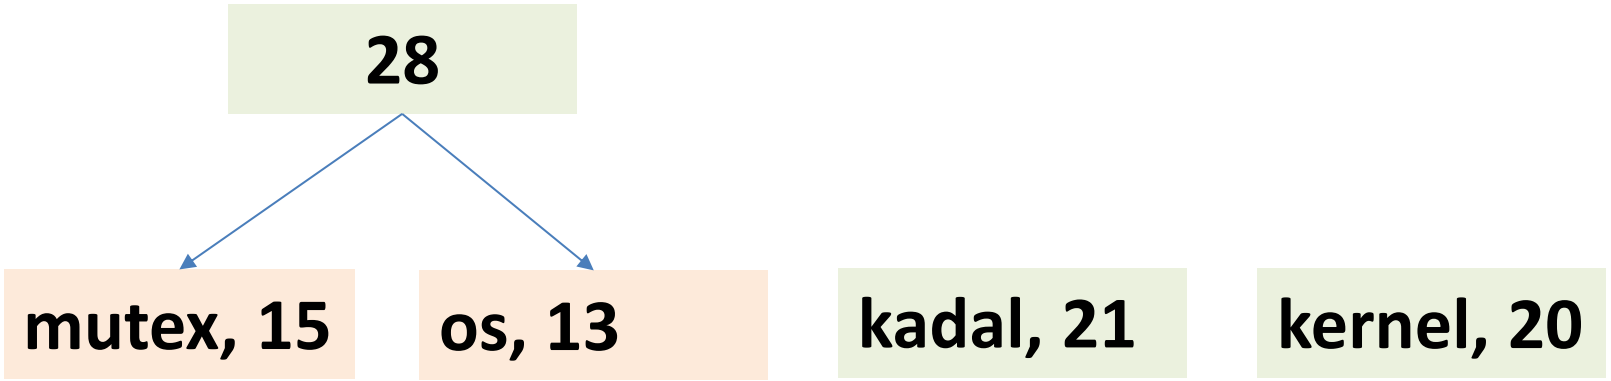

Hierarchical Softmax

Huffman Tree

Gabung dua buah kata dengan frekuensi paling kecil; dan proses ini dilakukan terus.

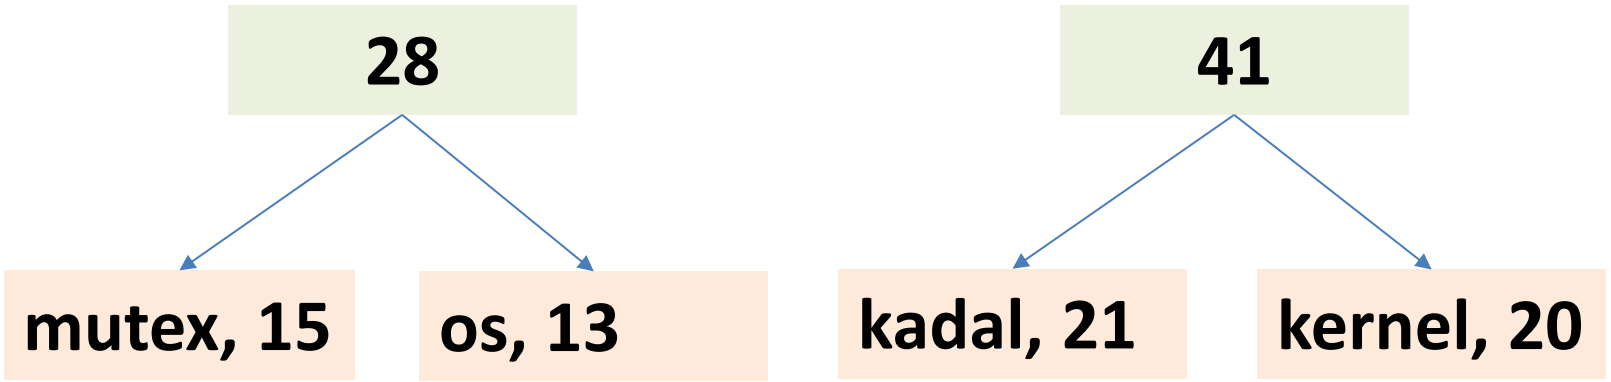

Hierarchical Softmax

Huffman Tree

Assign kode biner ke setiap kata di vocabulary

Gabung dua buah kata dengan frekuensi paling kecil; dan proses ini dilakukan terus.

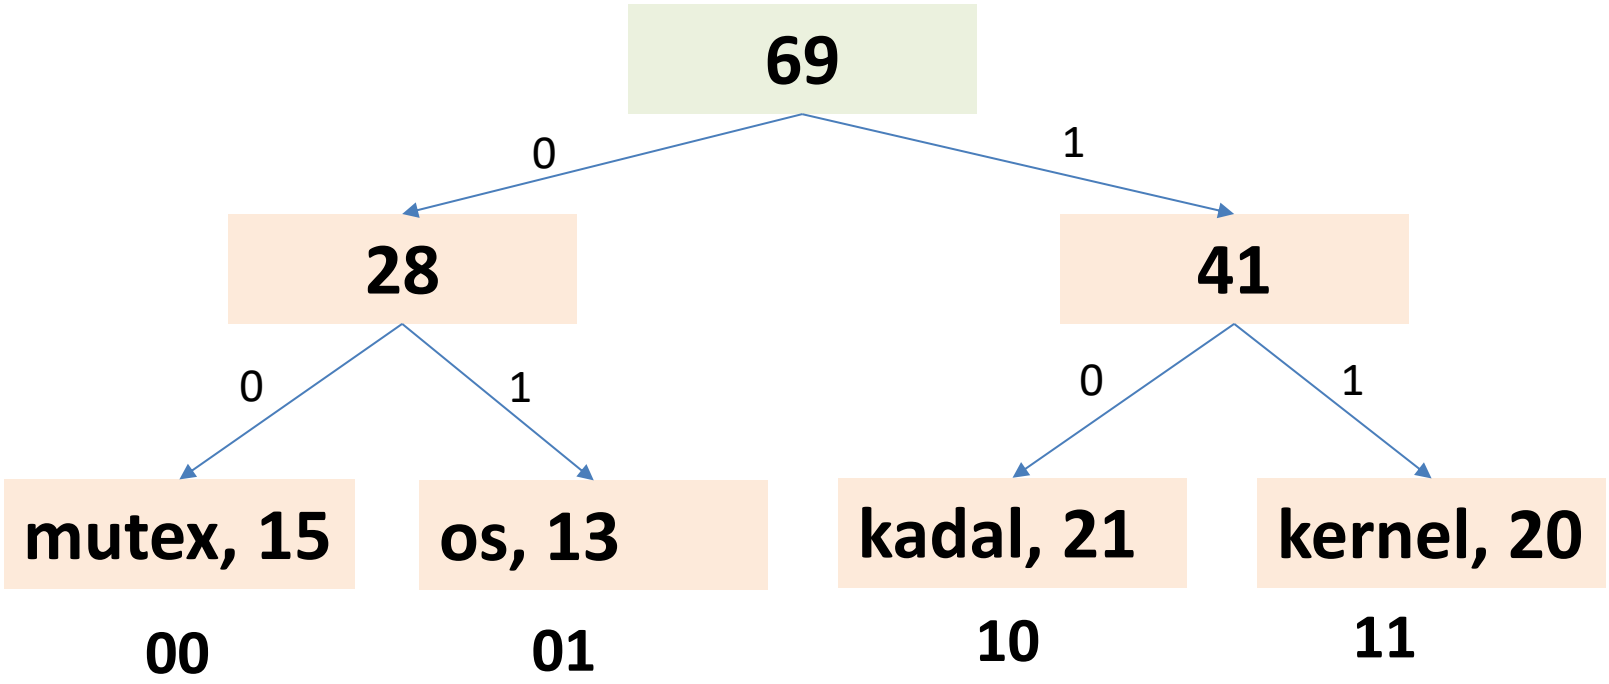

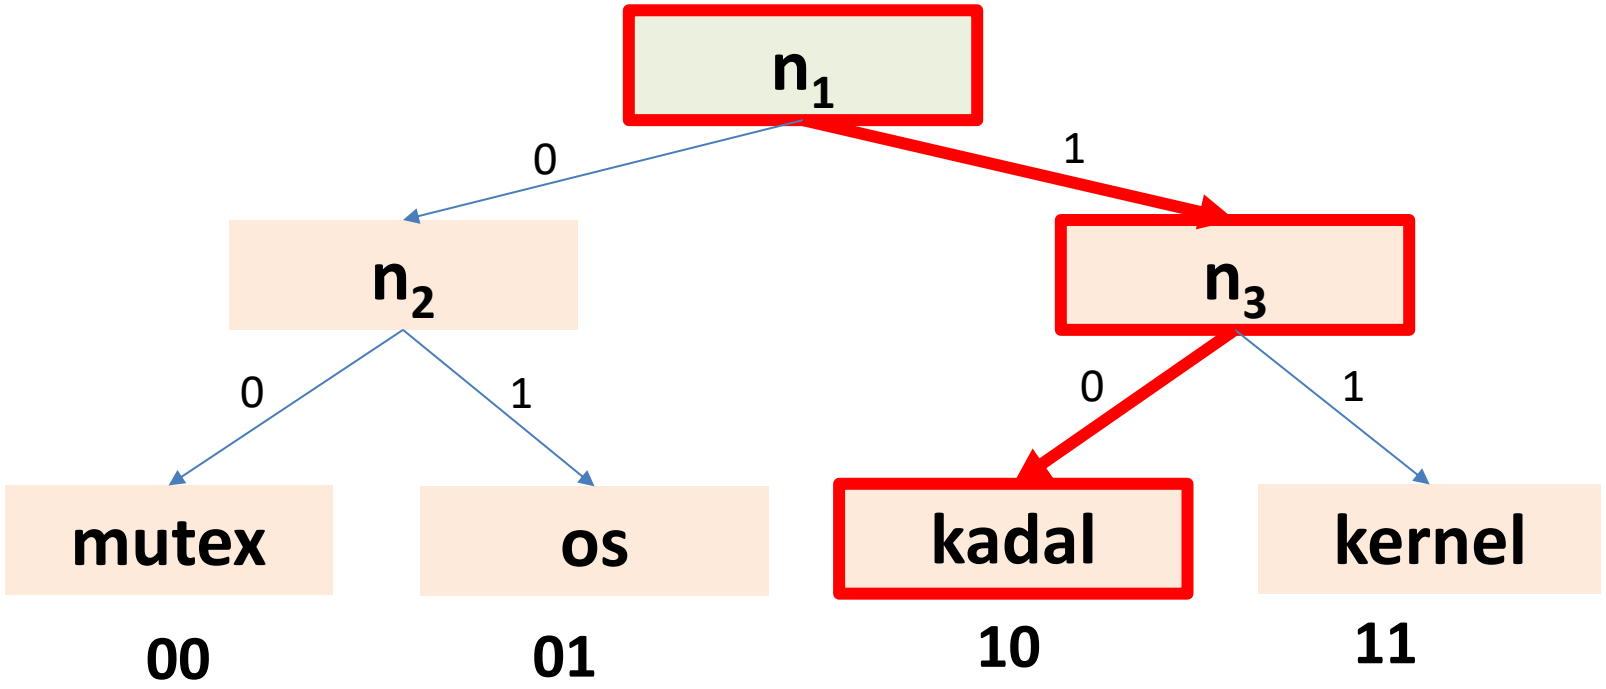

$$P(kadal|c) = P_{n_1}(right|c) \times P_{n_3}(left|c)$$

$$= (1 - P_{n_1}(left|c)) \times P_{n_3}(left|c)$$

$$P_n(left|c) = \sigma(v_n^T . center(c))$$

Trainable vector for node n

Hidden layer representation of the center c

Continuous Bag-of-Words

- **Mikolov's CBOW** looks at **n words** before and after the target words.
  - Non-linear hidden layer is also removed.
  - All word vectors get projected into the same position (**their vectors are averaged**)

- "Bag-of-Words" is because **the order of words in the history does not influence the projection**.

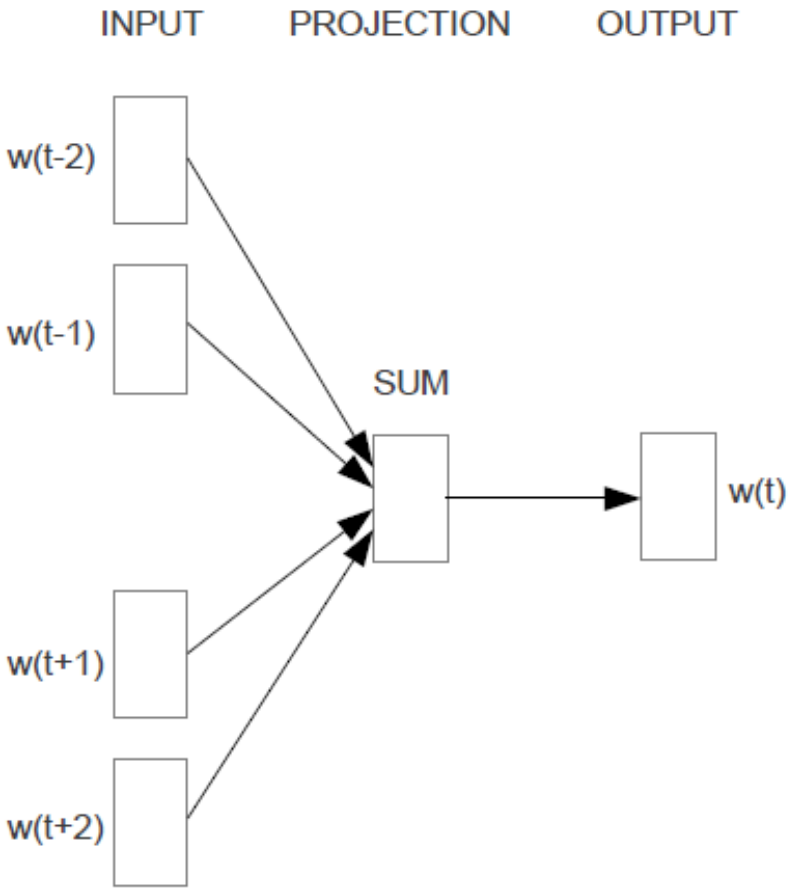

We seek a model for $P(w_t \mid w_{t-n} \ldots w_{t-1} w_{t+1} \ldots w_{t+n})$

Continuous Bag-of-Words

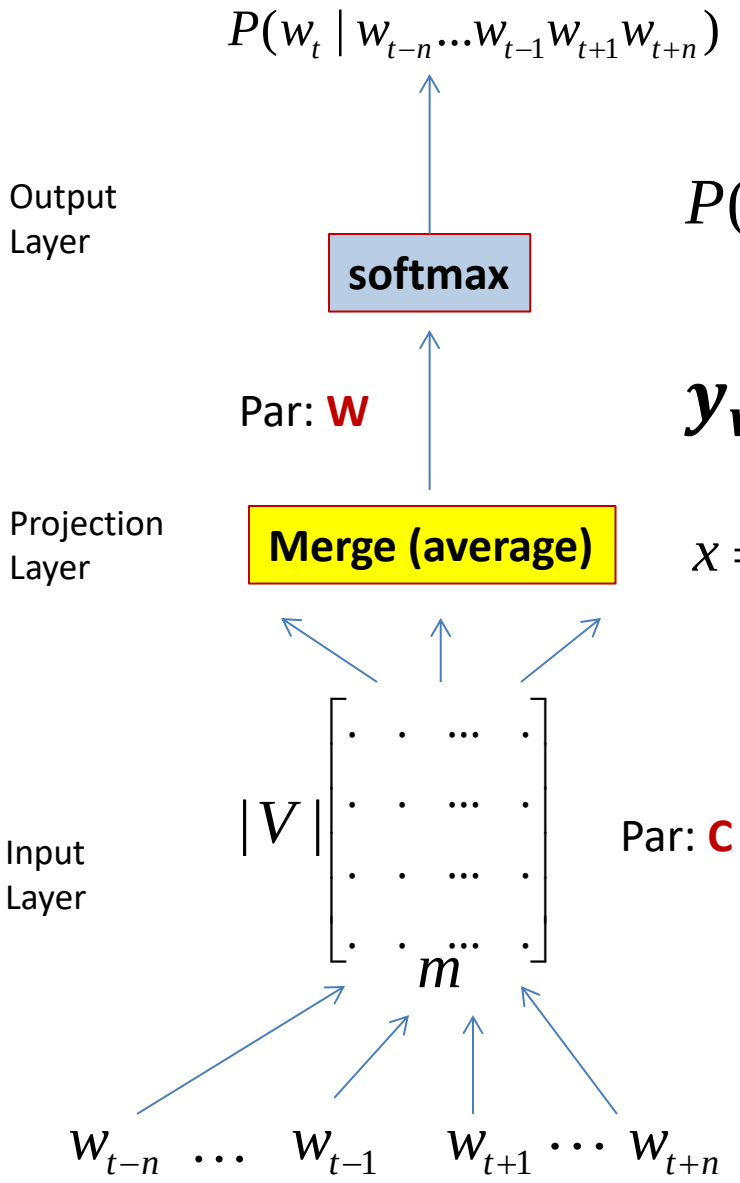

Feed-Forward Process

$$P(w_t \mid w_{t-n} \ldots w_{t-1} w_{t+1} \ldots w_{t+n}) = \frac{\exp(y_{w_t})}{\sum_{i \in V} \exp(y_i)}$$

$$\boldsymbol{y_{w_t} = W.x}$$

$$x = average(C(w_{t-n}), C(w_{t-1}), \ldots, C(w_{t+1}), C(w_{t+n}))$$

Total Parameters:

$$\theta = \{W, C\}$$

$$C \in R^{|V| \times m}$$

$$W \in R^{m \times |V|}$$

Continuous Bag-of-Words

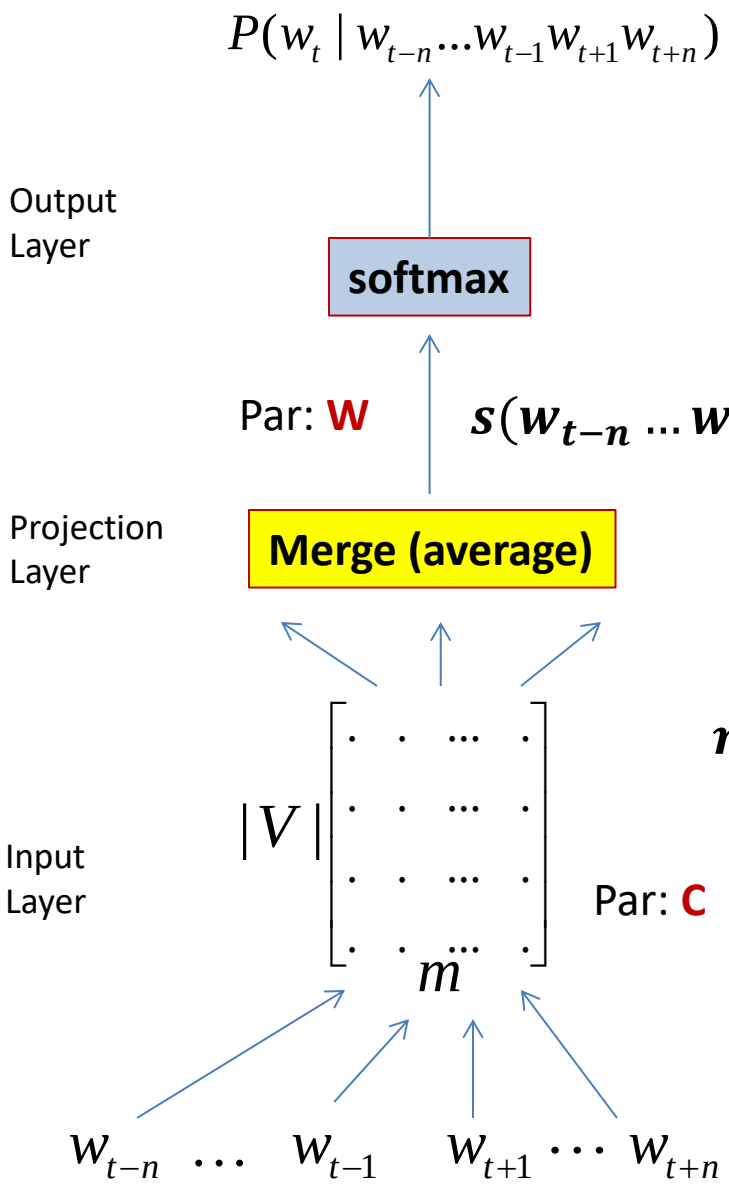

Dengan kata lain, CBOW juga bisa dinyatakan dengan:

$$P(w_t | w_{t-n} \ldots w_{t+n}) = \frac{exp(s(w_{t-n} \ldots w_{t+n}, w_t))}{\sum_{i \in V} s(w_{t-n} \ldots w_{t+n}, w_i)}$$

$$s(w_{t-n} \ldots w_{t+n}, w_i) = merge(w_{t-n} \ldots w_{t+n})^T . context(w_i)$$

Kolom di matriks W

$$merge(w_{t-n} \ldots w_{t+n}) = \frac{1}{2n} \sum_{t-n \leq j \leq t+j} center(w_j)$$

Baris di matriks C

Continuous Bag-of-Words

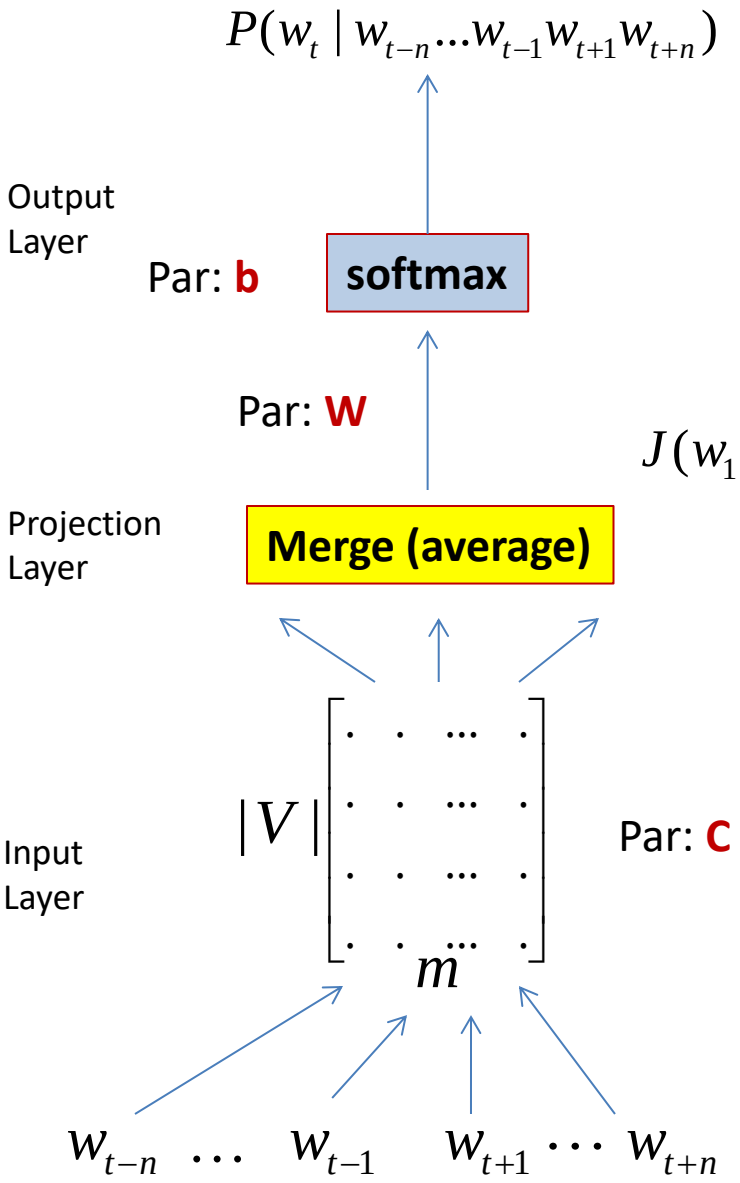

Training

Training is achieved by looking **θ** that maximizes the following Cost Function:

Given training data $w_1, w_2, w_3, \ldots, w_{T-1}, w_T$

$$J(w_1 \ldots w_T; \theta) = \frac{1}{T} \sum_{t=1}^{T} \log P(w_t \mid w_{t-n} \ldots w_{t-1} w_{t+1} \ldots w_{t+n}) + R(\theta)$$

Regularization terms

Continuous Bag-of-Words

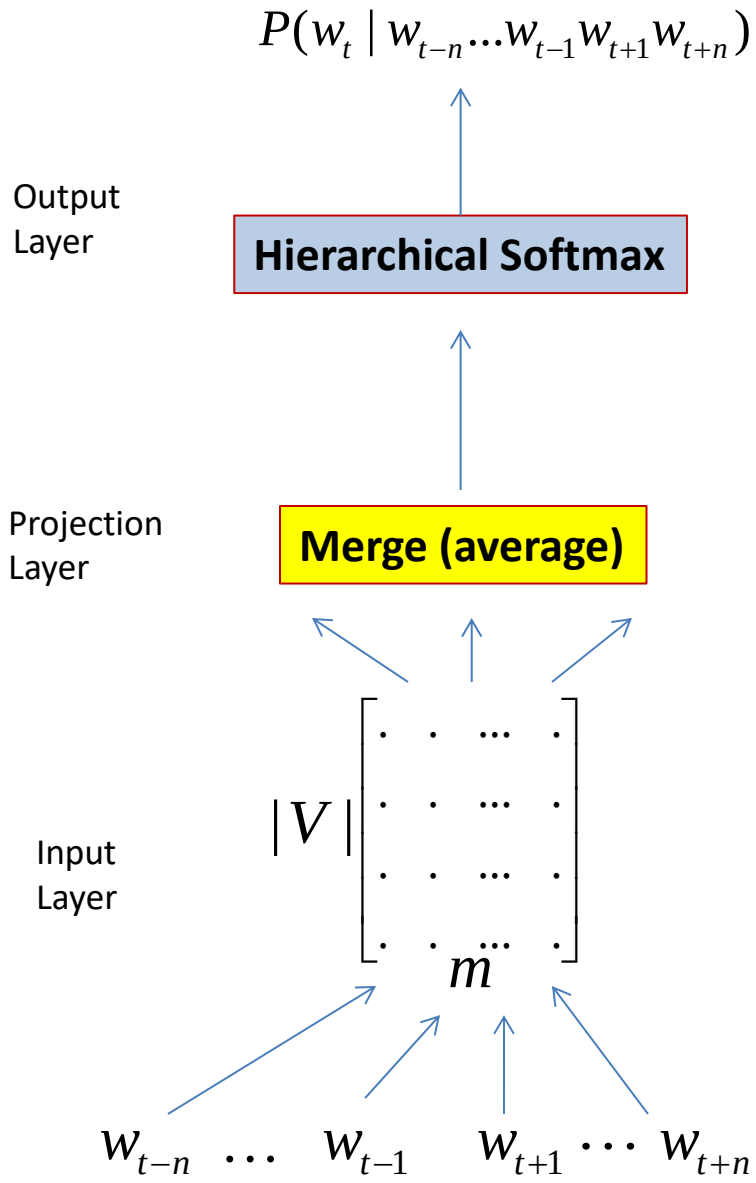

Training

Actually, if we use **vanilla softmax**, then the computational complexity per instance (**Q**) is still costly.

$$Q = N \times m + m \times |V|$$

biar komputasi softmax di ujung bisa lebih murah

To solve this problem, they use **Hierarchical Softmax layer**. This layer uses a **binary tree representation** of the output layer with |V| units.

$$Q = N \times m + m \times \log_2 |V|$$

(Morin & Bengio, 2005)

FastText (Bojanowski et al., TACL)

Subword Information

- Ekstensi dari Word2Vec -> bisa handle rare words atau kata yang out-of-vocabulary

- Perbedaannya adalah setiap kata tidak langsung diproyeksikan ke sebuah vector.
- Pada FastText, setiap kata “dipecah” dahulu menjadi “subwords”, dan setiap subword diproyeksikan ke vector.

Subword Information

- $\mathbf{w_t}$ = where

- Subwords dengan window = 3
  - <wh
  - whe
  - her
  - ere
  - re>
  - where

Kata asli itu sendiri diikutsertakan ke dalam set of ngrams

FastText – Skip-Gram Model

Given a word, what is the probability of its context word?

$$P(w_c|w_t) = softmax\big(s(w_c, w_t)\big) = \frac{\exp(s(w_c, w_t))}{\sum_{j=1}^{|Vocab|} \exp(s(w_j, w_t))}$$

Ingat bahwa, untuk kasus Word2Vec Skip-Gram biasa:

$$s(w_c, w_t) = center(\mathrm{w_t})^{\mathrm{T}}.context(\mathrm{w_c})$$

Untuk FastText, vektor kata adalah KOMBINASI dari vector Subwords !

Subword Information

- $\mathbf{w_t}$ = where

Center embedding dari subword "<wh"

- Subwords dengan window = 3
  - <wh -> $z_{g1} = [0.3, 0.1, \ldots]$
  - whe -> $z_{g2} = [0.1, 0.4, \ldots]$
  - her -> $z_{g3} = [0.5, 0.9, \ldots]$
  - ere -> $z_{g4} = [0.5, 0.5, \ldots]$
  - re> -> $z_{g5} = [0.3, 0.1, \ldots]$
  - where -> $z_{g6} = [0.1, 0.3, \ldots]$

Kata asli itu sendiri diikutsertakan ke dalam set of ngrams

Subword Information

- $\mathbf{w_t}$ = where

Representasi vector sebuah kata merupakan ”sum” dari semua vector subwords.

- Subwords dengan window = 3
  - <wh -> $z_{g1} = [0.3, 0.1, \ldots]$
  - whe -> $z_{g2} = [0.1, 0.4, \ldots]$
  - her -> $z_{g3} = [0.5, 0.9, \ldots]$
  - ere -> $z_{g4} = [0.5, 0.5, \ldots]$
  - re> -> $z_{g5} = [0.3, 0.1, \ldots]$
  - where -> $z_{g6} = [0.1, 0.3, \ldots]$

$$s(w_c, w_t) = \sum_g z_g^{\mathrm{T}}.context(\mathrm{w_c})$$

Kata asli itu sendiri diikutsertakan ke dalam set of ngrams